Министерство науки и высшего образования РФ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Ижевский государственный технический университет
имени М.Т. Калашникова»
(ИжГТУ имени М.Т. Калашникова)
Факультет «Математика и естественные науки»
Кафедра «Прикладная математика и информационные технологии»

Лабораторная работа № 1
по курсу **«Информационные технологии анализа и обработки данных»**
Вариант 7

Направление подготовки 01.03.02 «Прикладная математика»
Профиль – «Прикладной анализ данных и искусственный интеллект»

Проверил: В. Г. Суфиянов
доктор технических наук, профессор

Выполнил: М. А. Панин
студент группы Б23-183-1

Ижевск - 2026

СОДЕРЖАНИЕ

Введение **3**
Задание 1. Загрузка и описание данных **3**
Задание 2. Предобработка и первичный анализ **4**
Задание 3. Корреляционный анализ **4**
Задание 4. Регрессионный анализ **5**
Интервальные оценки и диагностика 6
Задание 5. Дисперсионный анализ **7**
Заключение **8**

Введение

Цель работы — освоить загрузку, предобработку и анализ данных средствами языка R. Исследуются связь профессионального стажа с годовым вознаграждением и различия вознаграждения между ступенями образования. Расчёты выполнены в Jupyter с ядром R 4.6.2.

Задание 1. Загрузка и описание данных

Вариант 7 предусматривает набор Stack Overflow Developer Survey 2011–2022. Для сопоставимости стажа, образования и оплаты использована одна волна с общей анкетой — 2022 год. Таблица за 2022 год в архиве Kaggle содержит повреждённый фрагмент, поэтому использован оригинальный выпуск Stack Overflow. В нём 73 268 строк и 79 столбцов. Строка соответствует одной анкете. При чтении проверены заполненность и уникальность идентификатора ответа.

Во фрагменте `csv_text` содержит текст исходной таблицы, а `columns` задаёт нужные для анализа поля. Типы столбцов определяются по заголовку до чтения данных.

Листинг 1.1 — Чтение нужных столбцов и проверка ключа анкеты

```
header <- names(read.csv(text = csv_text, nrows = 0L,
                         check.names = FALSE))
stopifnot(all(columns %in% header))
types <- ifelse(header %in% columns, "character", "NULL")
survey <- read.csv(
  text = csv_text, colClasses = types, check.names = FALSE,
  na.strings = c("", "NA"), encoding = "UTF-8"
)
response_id <- survey$ResponseId
stopifnot(!anyNA(response_id), !anyDuplicated(response_id))
```

Таблица 1.1 — Поля, использованные в расчётах

Поле	Назначение	Пропуски
`ResponseId`	Идентификатор анкеты	0
`MainBranch`	Категория деятельности	0
`Employment`	Категории занятости	1 559
`EdLevel`	Ступень образования	1 697
`YearsCodePro`	Профессиональный стаж, лет	21 435
`Country`	Страна проживания	1 497
`ConvertedCompYearly`	Годовое вознаграждение, USD	35 197

Задание 2. Предобработка и первичный анализ

Сравнение ограничено профессиональными разработчиками из США, указавшими полную занятость. Выбор одной страны уменьшает влияние различий между рынками труда. Для сравнения образования выделены бакалавриат, магистратура и докторская ступень. Остались записи с конечными значениями стажа и положительным вознаграждением. Категории стажа «меньше года» и «больше 50 лет» закодированы как 0,5 и 51 год соответственно.

Листинг 2.1 — Формирование общей выборки для моделей

```
analysis_data <- subset(
  prepared,
  is.finite(experience) & experience >= 0 &
    is.finite(salary) & salary > 0 & !is.na(education)
)
analysis_data$log_salary <- log(analysis_data$salary)
```

Из 73 268 анкет 9 133 удовлетворили условиям по стране, профессии и занятости. После проверки стажа, оплаты и образования рабочая выборка составила 6 161 анкету. Медиана стажа равна 8 годам, межквартильный интервал — от 4 до 15 лет. Медиана вознаграждения составила 150 000 долларов США в год, а среднее — 385 986. Для анализа связи использован натуральный логарифм оплаты, который уменьшает влияние правого хвоста распределения.

Таблица 2.1 — Годовое вознаграждение по ступеням образования

Ступень	Анкет	Медиана, USD	Среднее, USD
Бакалавриат	4 511	140 000	383 864
Магистратура	1 425	160 000	381 526
Докторская	225	170 000	456 753

Задание 3. Корреляционный анализ

Коэффициент Пирсона оценивает линейную связь стажа с логарифмом оплаты, а коэффициент Спирмена оценивает монотонную связь по рангам. Для обоих двусторонних тестов нулевая гипотеза утверждает, что соответствующий коэффициент корреляции равен нулю.

Листинг 3.1 — Расчёт корреляций Пирсона и Спирмена

```
pearson <- with(analysis_data, cor.test(
  experience, log_salary, method = "pearson"
))
spearman <- with(analysis_data, cor.test(
  experience, log_salary, method = "spearman", exact = FALSE
))
```

Таблица 3.1 — Корреляция стажа с логарифмом вознаграждения

Метод	Оценка	95 %-й интервал	p
Пирсон	0,1073	[0,0825; 0,1319]	$< 2{,}2 \cdot 10^{-16}$
Спирмен	0,3250	—	$< 2{,}2 \cdot 10^{-16}$

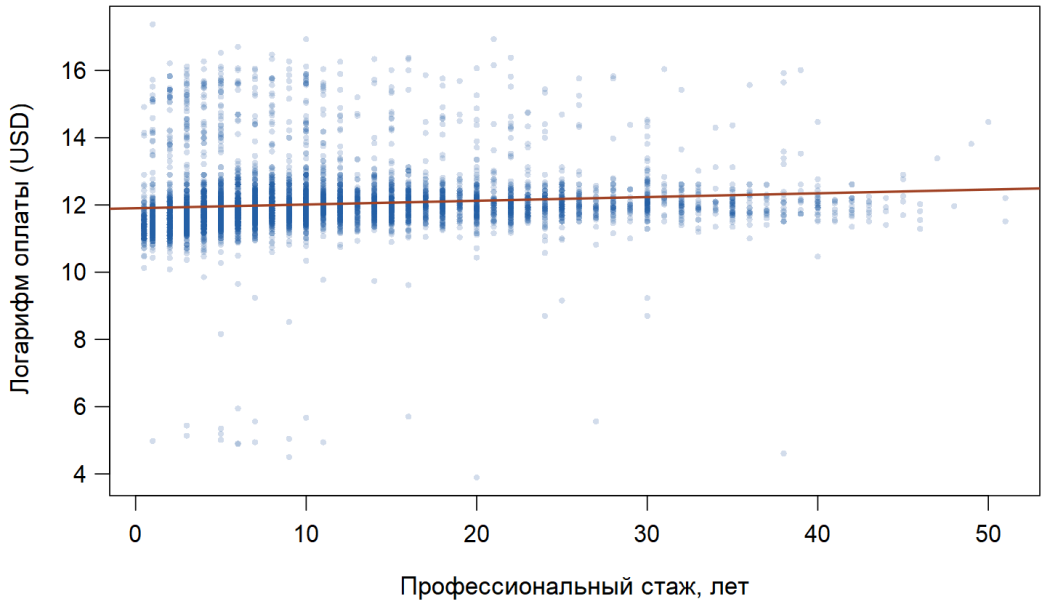


Рисунок 3.1 — Связь профессионального стажа с логарифмом вознаграждения

Связь положительна по обоим коэффициентам. Линейная связь слабая, а ранговая выражена сильнее. На диаграмме заметен широкий разброс оплаты при одинаковом стаже.

Задание 4. Регрессионный анализ

Парная модель использует профессиональный стаж. Во множественную модель добавлены индикаторы двух ступеней образования, а бакалавриат выбран базовой категорией. Для анкеты i с годовым вознаграждением Y_i и стажем x_i модель имеет вид

$$\ln(Y_i) = \beta_0 + \beta_1 x_i + \beta_2 I_{\text{маг},i} + \beta_3 I_{\text{док},i} + \varepsilon_i.$$

Листинг 4.1 — Подгонка и сравнение вложенных моделей

```
simple_model <- lm(
  log_salary ~ experience, data = analysis_data
)
adjusted_model <- lm(
  log_salary ~ experience + education, data = analysis_data
)
anova(simple_model, adjusted_model)
```

Таблица 4.1 — Коэффициенты множественной регрессии

Член модели	Оценка	Ст. ошибка	p
Свободный член	11,881990	0,019637	$< 2 \cdot 10^{-16}$
Стаж, год	0,010526	0,001319	$1{,}73 \cdot 10^{-15}$
Магистратура	0,091529	0,028623	0,00139
Докторская	0,160612	0,064052	0,01218

При фиксированном образовании дополнительный год стажа связан с увеличением геометрического среднего вознаграждения на 1,06 % (95 %-й интервал от 0,80 до 1,32 %). Для перевода коэффициента в проценты использовано $100 \cdot (\exp(\beta) - 1)$. При одинаковом стаже оценки для магистратуры и докторской ступени выше бакалавриата на 9,58 % и 17,42 % соответственно. Доля объяснённой вариации логарифма вознаграждения выросла с 1,15 до 1,39 %.

Интервальные оценки и диагностика

Для выпускника бакалавриата со стажем восемь лет прогноз на логарифмической шкале равен 11,966. Прогнозный интервал для отдельной анкеты шире доверительного интервала среднего отклика, поскольку учитывает остаточный разброс ответов.

Листинг 4.2 — Доверительный и прогнозный интервалы для профиля

```
typical_profile <- data.frame(
  experience = median(analysis_data$experience),
  education = "Bachelor"
)
predict(adjusted_model, typical_profile, interval = "confidence")
predict(adjusted_model, typical_profile, interval = "prediction")
```

Таблица 4.2 — Интервалы на логарифмической шкале

95 %-й интервал	Оценка	Нижняя	Верхняя
Для среднего отклика	11,966	11,938	11,994
Для отдельной анкеты	11,966	10,130	13,802

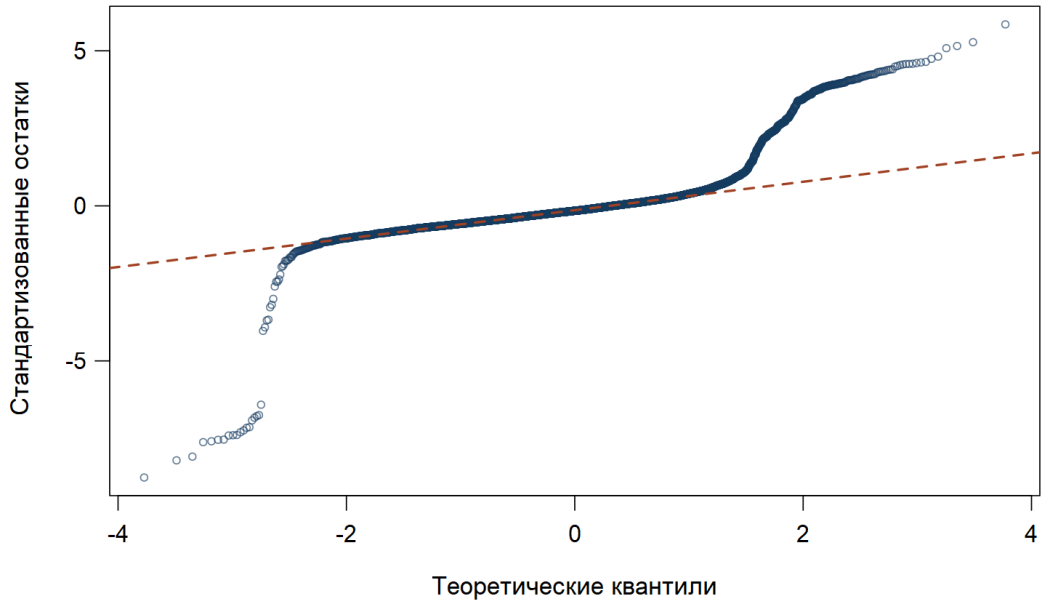


Рисунок 4.1 — Квантили стандартизованных остатков

На Q–Q-графике хвосты заметно отклоняются от линии нормального распределения. Крайние значения влияют на разброс остатков даже после логарифмирования. Точность индивидуального прогноза по двум признакам ограничена.

Задание 5. Дисперсионный анализ

Однофакторный дисперсионный анализ проверяет равенство средних логарифмов вознаграждения для трёх образовательных групп. Тест Уэлча проверяет ту же гипотезу без предположения об одинаковых дисперсиях. Частный F-тест сравнивает модели со стажем и с комбинацией стажа и образования.

Листинг 5.1 — Однофакторный анализ и тест Уэлча

```
education_anova <- aov(
  log_salary ~ education, data = analysis_data
)
summary(education_anova)
welch <- oneway.test(
  log_salary ~ education, data = analysis_data, var.equal = FALSE
)
welch
```

Таблица 5.1 — Результаты сравнения образовательных групп

Критерий	***F***	**Степени свободы**	***p***
Однофакторный ANOVA	11,42	2 и 6 158	$1{,}12 \cdot 10^{-5}$
Тест Уэлча	11,573	2 и 584,51	$1{,}178 \cdot 10^{-5}$
Частный F-тест	7,453	2 и 6 157	0,000585

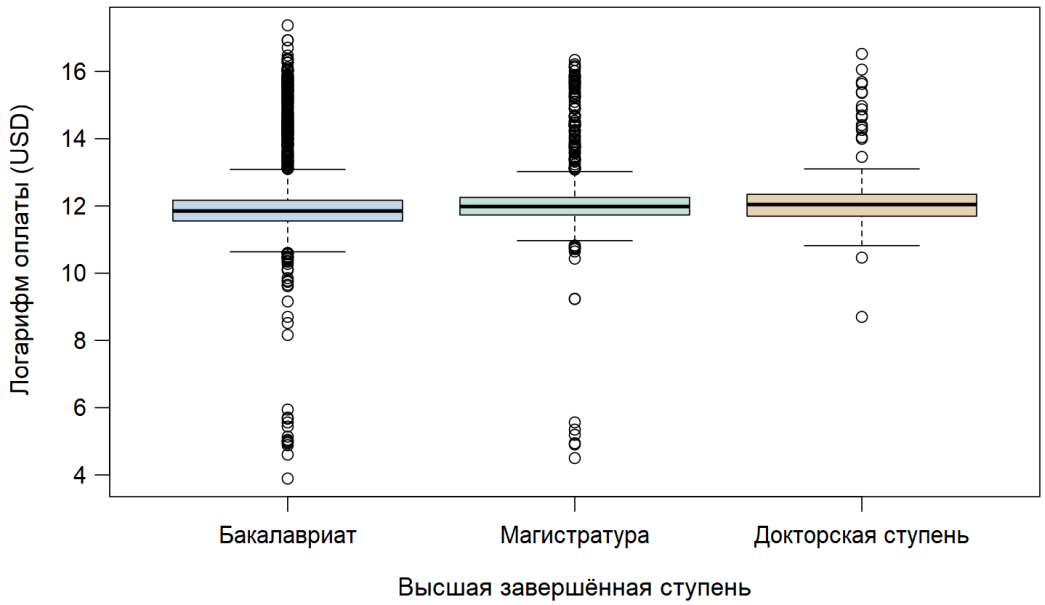


Рисунок 5.1 — Логарифм вознаграждения по ступеням образования

При уровне значимости 0,05 равенство средних логарифмов оплаты отвергается. Различие сохраняется после учёта стажа. На рисунке видны пересекающиеся распределения и крайние значения во всех группах.

Заключение

В выборке из 6 161 анкеты стаж положительно связан с оплатой. Добавление ступени образования статистически значимо, а полная модель объясняет 1,39 % вариации логарифма оплаты. Результаты описывают ассоциации в выбранной подгруппе добровольного опроса. Для причинной интерпретации потребовались бы данные о специализации, компании и регионе работы.