Министерство науки и высшего образования РФ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Ижевский государственный технический университет
имени М.Т. Калашникова»
(ИжГТУ имени М.Т. Калашникова)
Факультет «Математика и естественные науки»
Кафедра «Прикладная математика и информационные технологии»

Лабораторная работа № 2
по курсу **«Информационные технологии анализа и обработки данных»**
Вариант 7

Направление подготовки 01.03.02 «Прикладная математика»
Профиль – «Прикладной анализ данных и искусственный интеллект»

Проверил: В. Г. Суфиянов
доктор технических наук, профессор

Выполнил: М. А. Панин
студент группы Б23-183-1

Ижевск - 2026

СОДЕРЖАНИЕ

Введение 3
Задание 1. Загрузка и согласование данных 3
Задание 2. Построение OLAP-куба 3
Задание 3. Агрегация и детализация 4
Задание 4. Географические срезы 5
Задание 5. Динамика ответов 7
Заключение 7

Введение

Цель работы — развернуть OLAP-куб на данных Stack Overflow Developer Survey и выполнить запросы по времени и географии. Реализация выполнена на R 4.6.2 в Jupyter. Для представления и подготовки таблиц использованы `tibble` и `dplyr`, для схемы хранилища и запросов — `rolap`.

Задание 1. Загрузка и согласование данных

Источники варианта 7 — двенадцать ежегодных таблиц с анкетами. Волны 2011–2021 годов взяты из архива Kaggle. Повреждённая таблица за 2022 год заменена оригинальным выпуском Stack Overflow. Для каждой анкеты сохранены год волны и географическое поле. Служебные строки в выпусках 2011–2015 годов исключены.

Названия географического поля различаются между выпусками. После чтения удалены краевые пробелы, а несколько явно эквивалентных названий приведены к одной форме. Например, `United States of America` приведено к `United States`. Укрупнённые регионы, например `Other Europe`, сохранены отдельно. Пустые ответы отнесены к категории «Не указано». В 2022 году её доля составила 1 497 из 73 268 анкет, или 2,04 %.

Листинг 1.1 — Нормализация места проживания и построение десятилетия

```
responses <- responses_raw |>
  mutate(
    place = trimws(place),
    place = coalesce(na_if(place, ""), "Не указано"),
    place = recode(place, !!!place_names),
    decade = paste0(year %/% 10L * 10L, "-e")
  )
```

Задание 2. Построение OLAP-куба

Хранилище организовано по схеме «звезда». Зерно таблицы фактов — пара «год, место проживания». Для каждой встречающейся пары число анкет вычисляется функцией `count`. Измерение `wave` содержит год и десятилетие, измерение `geography` — согласованную географическую категорию. В таблице `survey` эти измерения связаны с фактами ключами `wave_key` и `geography_key`.

Мера $n_{y,g}$ считает анкеты года y в категории g. Агрегация `SUM` в `rolap` даёт годовой итог $N_y = \sum_g n_{y,g}$. Анкеты без географии входят в сумму через категорию «Не указано».

Листинг 2.1 — Определение схемы и развёртывание хранилища

```
fact_input <- count(
  responses, decade, year, place, name = "responses"
)
survey_schema <- star_schema() |>
  define_facts(name = "survey", measures = "responses",
               agg_functions = "SUM") |>
  define_dimension(name = "wave",
                   attributes = c("decade", "year")) |>
  define_dimension(name = "geography", attributes = "place")
survey_db <- star_database(survey_schema, fact_input)
```

Листинг 2.2 — Размеры таблиц и контроль общей суммы меры

```
star_tables <- as_tibble_list(survey_db)
tibble(
  table = names(star_tables),
  rows = vapply(star_tables, nrow, integer(1L)),
  columns = vapply(star_tables, ncol, integer(1L))
)
stopifnot(sum(star_tables$survey$responses) == nrow(responses))
```

Таблица 2.1 — Размеры таблиц хранилища

Таблица	Назначение	Строк	Столбцов
`wave`	Год и десятилетие	12	3
`geography`	Место проживания	281	2
`survey`	Факты и число анкет	1 600	4

Сумма меры по 1 600 ячейкам равна 568 855. Это совпадает с числом анкет после загрузки и нормализации.

Задание 3. Агрегация и детализация

При свёртке (`roll-up`) из запроса исключено измерение географии. Мера суммируется сначала по годам, затем по десятилетиям. За 2011–2019 годы получено 347 687 анкет, за 2020–2022 годы — 221 168. Оба итога относятся к годам, представленным в наборе. При детализации (`drill-down`) итог 2020-х раскрывается по трём отдельным волнам.

Таблица 3.1 — Число анкет по годам

Год	Анкет	Год	Анкет
2011	2 813	2017	51 392
2012	6 243	2018	98 855
2013	9 742	2019	88 883
2014	7 643	2020	64 461
2015	26 086	2021	83 439
2016	56 030	2022	73 268

Листинг 3.1 — Свёртка по десятилетиям

```
decade_query <- survey_db |>
  star_query() |>
  select_dimension(name = "wave", attributes = "decade") |>
  select_fact(name = "survey", measures = "responses")
decade_tables <- as_single_tibble_list(
  run_query(survey_db, decade_query)
)
```

Листинг 3.2 — Детализация меры по отдельным годам

```
year_query <- survey_db |>
  star_query() |>
  select_dimension(name = "wave", attributes = "year") |>
  select_fact(name = "survey", measures = "responses")
year_tables <- run_query(survey_db, year_query) |>
  as_single_tibble_list()
year_totals <- year_tables$survey |>
  mutate(year = as.integer(year)) |>
  arrange(year)
filter(year_totals, year >= 2020L)
```

Сумма итогов по десятилетиям совпадает с общим числом анкет. Годовые итоги запроса также совпали с прямым подсчётом строк исходных данных по годам.

Задание 4. Географические срезы

Одномерный срез (`slice`) фиксирует 2022 год и показывает число ответов по географическим категориям. Для доли каждой категории знаменателем служит размер всей волны, включая анкеты без заполненной географии. Наибольшее число ответов в срезе поступило из США.

Листинг 4.1 — Срез по году и доли ответов по странам

```
geo_query <- survey_db |>
  star_query() |>
  select_dimension(name = "wave", attributes = "year") |>
  select_dimension(name = "geography", attributes = "place") |>
  select_fact(name = "survey", measures = "responses")
slice_query <- geo_query |>
  filter_dimension(name = "wave", year == "2022")
latest <- run_query(survey_db, slice_query) |>
  as_single_tibble_list()
latest$survey |>
  mutate(share_pct = 100 * responses / sum(responses)) |>
  filter(place != "Не указано") |>
  slice_max(responses, n = 5L, with_ties = FALSE)
```

Таблица 4.1 — Пять стран с наибольшим числом анкет за 2022 год

Страна	Анкет	Доля, %
США	13 543	18,48
Индия	6 639	9,06
Германия	5 395	7,36
Великобритания	4 190	5,72
Канада	2 490	3,40

Многомерный срез (`dice`) ограничивает запрос одновременно тремя волнами и тремя странами. Операция поворота выводит годы строками, а страны столбцами.

Листинг 4.2 — Ограничение по двум измерениям и поворот среза

```
dice_query <- geo_query |>
  filter_dimension(
    name = "wave", year %in% c("2020", "2021", "2022")
  ) |>
  filter_dimension(
    name = "geography",
    place %in% c("United States", "India", "Germany")
  )
recent <- run_query(survey_db, dice_query) |>
  as_single_tibble_list()
xtabs(responses ~ year + place, data = recent$survey)
```

Таблица 4.2 — Число ответов в трёх странах за 2020–2022 годы

Год	Германия	Индия	США
2020	3 890	8 403	12 469
2021	5 625	10 511	15 288
2022	5 395	6 639	13 543

В 2022 году число анкет уменьшилось во всех трёх выбранных странах относительно 2021 года. Самое заметное падение в абсолютных числах — в Индии, на 3 872 ответа.

Задание 5. Динамика ответов

Максимальная волна пришлась на 2018 год и составила 98 855 анкет. После снижения в 2019–2020 годах число ответов выросло в 2021 году, а в 2022 году уменьшилось с 83 439 до 73 268. Относительное изменение за последний год составило

$$\left(\frac{73\ 268}{83\ 439} - 1\right) \cdot 100\ \% \approx -12{,}2\ \%.$$

Листинг 5.1 — Поиск наибольшей волны и расчёт изменения

```
peak_wave <- slice_max(year_totals, responses, n = 1L,
                       with_ties = FALSE)
latest_total <- filter(year_totals, year == 2022L)$responses
previous_total <- filter(year_totals, year == 2021L)$responses
relative_change <- 100 * (latest_total / previous_total - 1)
```

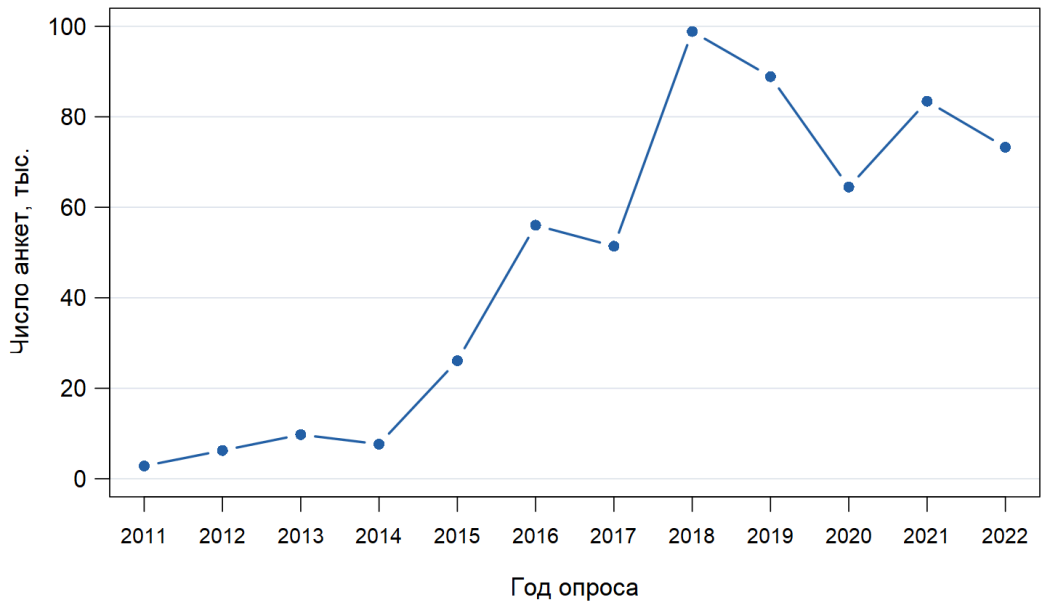


Рисунок 5.1 — Размер волны опроса по годам

Заключение

Куб охватывает 568 855 анкет за 2011–2022 годы. Итоги срезов и свёртки проверены прямым подсчётом анкет. Межгодовое сравнение географии зависит от состава вариантов ответа, поскольку ранние волны включают укрупнённые регионы.