Министерство науки и высшего образования РФ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Ижевский государственный технический университет
имени М.Т. Калашникова»
(ИжГТУ имени М.Т. Калашникова)
Факультет «Математика и естественные науки»
Кафедра «Прикладная математика и информационные технологии»

Лабораторная работа № 3
по курсу **«Информационные технологии анализа и обработки данных»**
Вариант 7

Направление подготовки 01.03.02 «Прикладная математика»
Профиль – «Прикладной анализ данных и искусственный интеллект»

Проверил: В. Г. Суфиянов
доктор технических наук, профессор

Выполнил: М. А. Панин
студент группы Б23-183-1

Ижевск - 2026

СОДЕРЖАНИЕ

Введение 3
Задание 1. Подготовка данных 3
Задание 2. Агрегирование данных 4
Задание 3. Форматирование и выгрузка 6
Задание 4. Визуализация результатов 6
Заключение 8

Введение

Цель работы — освоить трансформацию и визуализацию данных на языке R. По заданию требуется построить сводные таблицы в `pivottabler`, оформить их для Excel и Word и представить результаты анализа средствами `ggplot2`.

Варианту 7 соответствует набор Stack Overflow Developer Survey 2011–2022. Для анализа формата работы выбрана волна 2022 года, в которой есть отдельный вопрос `RemoteWork`. После анкеты с идентификатором около 68 810 в копии Kaggle обнаружены посторонние двоичные данные. Расчёты выполнены по официальному выпуску Stack Overflow.

Задание 1. Подготовка данных

Из 73 268 исходных анкет отбирались респонденты, указавшие полную занятость. Поскольку вопрос допускает несколько ответов, признак полной занятости проверялся как отдельная позиция списка `Employment`. Для сравнения исключены записи без страны, распознанного формата работы или идентификатора. Каждая анкета учитывалась один раз по `ResponseId`. Вектор `work_labels` сопоставляет исходным ответам три русских обозначения формата.

Листинг 1.1 — Отбор анкет с полной занятостью

```
workers <- survey |>
  filter(grepl(
    "(^|;)Employed, full-time(;|$)", Employment
  )) |>
  mutate(format = factor(
    unname(work_labels[RemoteWork]),
    levels = unname(work_labels)
  )) |>
  filter(
    !is.na(ResponseId), !is.na(Country), !is.na(format)
  ) |>
  distinct(ResponseId, .keep_all = TRUE)
```

Для первой сводки взяты восемь стран с наибольшим числом ответов после фильтрации. Для второй анкеты распределены по шести интервалам профессионального стажа из `YearsCodePro`. Два текстовых ответа о стаже менее года и свыше 50 лет сохранены как отдельные категории. Пустые значения стажа в этой сводке исключены.

Листинг 1.2 — Отбор стран по числу анкет

```
top_countries <- workers |>
  count(Country, name = "responses") |>
  arrange(desc(responses), Country) |>
  slice_head(n = 8L)
country_data <- workers |>
  filter(Country %in% top_countries$Country) |>
  mutate(country = factor(
    Country, levels = top_countries$Country
  ))
```

Листинг 1.3 — Группировка анкет по стажу программирования

```
experience_levels <- c(
  "<1", "1-4", "5-9", "10-19", "20-50", ">50"
)
experience_data <- workers |>
  mutate(
    years = suppressWarnings(as.numeric(YearsCodePro)),
    experience = case_when(
      YearsCodePro == "Less than 1 year" ~ "<1",
      YearsCodePro == "More than 50 years" ~ ">50",
      years >= 1 & years < 5 ~ "1-4",
      years >= 5 & years < 10 ~ "5-9",
      years >= 10 & years < 20 ~ "10-19",
      years >= 20 & years <= 50 ~ "20-50"
    ),
    experience = factor(experience, levels = experience_levels)
  ) |>
  filter(!is.na(experience))
```

Таблица 1.1 — Число анкет на этапах подготовки

Набор	Анкет
Исходный выпуск 2022 года	73 268
Полная занятость, известны страна и формат работы	49 188
Восемь стран с наибольшим числом анкет	27 726
Анкеты с известной категорией стажа	45 566

Задание 2. Агрегирование данных

Для каждого сочетания признака строк и формата работы вычислялось число анкет `n()`. Строки первой таблицы образованы странами, строки второй — интервалами стажа. Сводки включают итоги по обоим измерениям.

Листинг 2.1 — Расчёт численностей по стране и формату работы

```
country_pivot <- pivottabler::PivotTable$new()
country_pivot$addData(country_data)
country_pivot$addRowDataGroups(
  "country", totalCaption = "Всего"
)
country_pivot$addColumnDataGroups(
  "format", totalCaption = "Всего"
)
country_pivot$defineCalculation(
  calculationName = "Responses", summariseExpression = "n()"
)
country_pivot$evaluatePivot()
```

Таблица 2.1 — Число анкет по стране и формату работы

Страна	Удалённо	Гибридно	В офисе	Всего
США	6 037	3 395	1 065	10 497
Индия	1 626	1 788	955	4 369
Германия	1 077	2 101	363	3 541
Великобритания	1 232	1 674	226	3 132
Канада	1 098	606	105	1 809
Бразилия	1 073	352	187	1 612
Франция	269	1 066	248	1 583
Испания	571	486	126	1 183
Всего	**12 983**	**11 468**	**3 275**	**27 726**

В США на удалённый формат приходится 57,5 % ответов, а в Германии гибридный формат составляет 59,3 %. Проценты рассчитаны относительно числа анкет каждой страны из таблицы 2.1.

В таблице 2.2 нулём обозначено отсутствие анкет в сочетании «стаж свыше 50 лет и работа в офисе». В выгрузках это сочетание отображается пустой ячейкой.

Таблица 2.2 — Число анкет по профессиональному стажу и формату работы

Стаж, лет	Удалённо	Гибридно	В офисе	Всего
< 1	522	730	467	1 719
1–4	4 721	5 859	2 727	13 307
5–9	5 542	5 844	1 580	12 966
10–19	5 274	5 067	1 083	11 424
20–50	2 847	2 566	727	6 140
> 50	8	2	0	10
Всего	**18 914**	**20 068**	**6 584**	**45 566**

Задание 3. Форматирование и выгрузка

Для таблиц по стране и по стажу выбраны тёмно-синий и бирюзовый заголовки. Числовые итоги выделены полужирным. Метод `writeToExcelWorksheet` передаёт сводку и её оформление из `pivottabler` в книгу Excel. Сводки записаны на листы «По странам» и «По стажу».

Для Word рассчитанные сводки извлечены методом `asDataFrame` и оформлены через `flextable`. Документ Word содержит обе таблицы с названиями и итоговыми строками. Итоги в выгрузках совпадают с рассчитанными сводками.

Листинг 3.1 — Заполнение листа Excel и оформление таблицы Word

```
workbook <- openxlsx::createWorkbook()
openxlsx::addWorksheet(workbook, "По странам")
country_pivot$writeToExcelWorksheet(
  wb = workbook, wsName = "По странам", topRowNumber = 2L,
  leftMostColumnNumber = 2L, showRowGroupHeaders = TRUE
)
country_table <- country_pivot$asDataFrame(
  rowGroupsAsColumns = TRUE
)
word_table <- flextable::flextable(country_table) |>
  flextable::theme_vanilla() |>
  flextable::bg(bg = "#173D62", part = "header")
```

Задание 4. Визуализация результатов

На рисунке 4.1 показаны 27 726 анкет из восьми стран. Сегменты разделяют ответы по формату работы. Самый длинный столбец у США, которым соответствуют 10 497 анкет.

Листинг 4.1 — Столбчатая диаграмма форматов работы по странам

```
country_counts <- country_data |>
  count(country, format, name = "responses")
ggplot(country_counts, aes(
  x = responses, y = factor(country, rev(levels(country))),
  fill = format
)) +
  geom_col() +
  scale_fill_manual(values = work_colours) +
  scale_y_discrete(labels = scales::label_wrap(26))
```

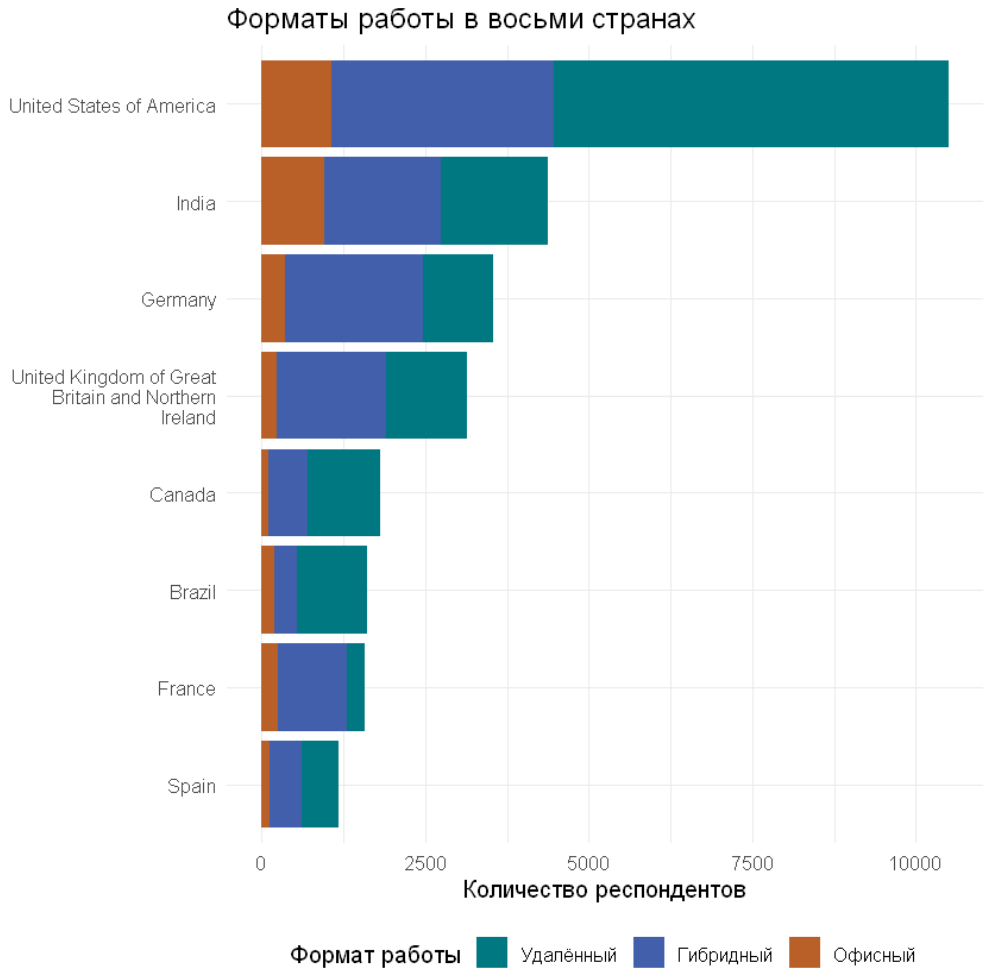


Рисунок 4.1 — Распределение анкет по формату работы в восьми странах

На рисунке 4.2 сравниваются доли форматов работы. Для группы стажа g и формата r доля равна

$$p_{g,r} = \frac{n_{g,r}}{\sum_{j} n_{g,j}},$$

где $n_{g,r}$ — число анкет в ячейке сводки. Проверка в R подтвердила, что $\sum_{r} p_{g,r} = 1$ для каждой группы.

Листинг 4.2 — Расчёт и проверка долей по группам стажа

```
experience_shares <- experience_data |>
  count(experience, format, name = "responses") |>
  group_by(experience) |>
  mutate(share = responses / sum(responses)) |>
  ungroup()
share_check <- experience_shares |>
  group_by(experience) |>
  summarise(total = sum(share))
stopifnot(all(abs(share_check$total - 1) < 1e-12))
```

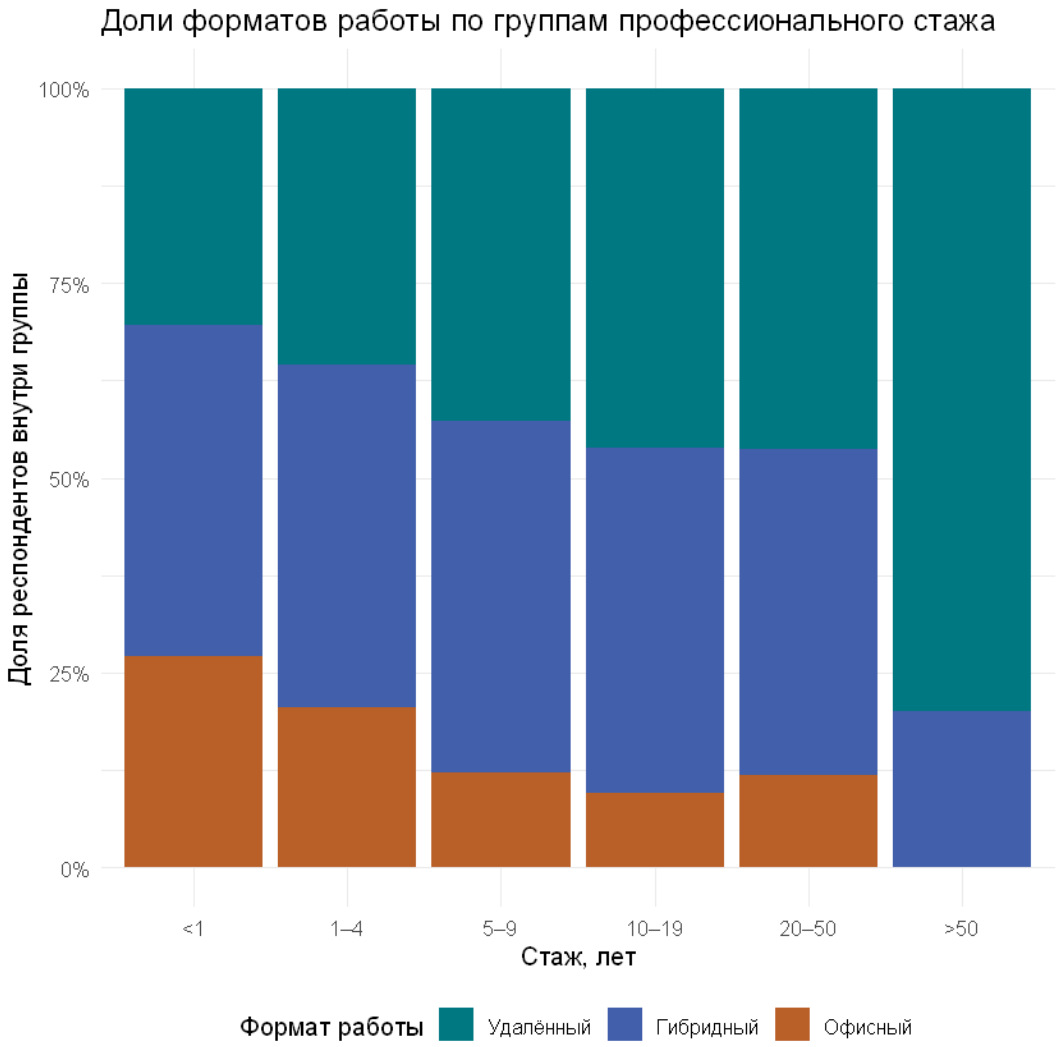


Рисунок 4.2 — Доли форматов работы внутри групп профессионального стажа

Заключение

Среди 49 188 отобранных анкет гибридный формат оказался наиболее частым (21 585 ответов, 43,9 %). Удалённый формат составил 40,7 %, офисный — 15,4 %. Среди участников со стажем свыше 50 лет удалённо работают 8 из 10 респондентов. Доли относятся к участникам опроса.