Министерство науки и высшего образования РФ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Ижевский государственный технический университет
имени М.Т. Калашникова»
(ИжГТУ имени М.Т. Калашникова)
Факультет «Математика и естественные науки»
Кафедра «Прикладная математика и информационные технологии»

Лабораторная работа № 4
по курсу **«Информационные технологии анализа и обработки данных»**
Вариант 7

Направление подготовки 01.03.02 «Прикладная математика»
Профиль – «Прикладной анализ данных и искусственный интеллект»

Проверил: В. Г. Суфиянов
доктор технических наук, профессор

Выполнил: М. А. Панин
студент группы Б23-183-1

Ижевск - 2026

СОДЕРЖАНИЕ

Введение 3
Задание 1. Подготовка данных 3
Задание 2. Диагностика числовых выбросов 4
Задание 3. Гиперграфовый анализ 5
Задание 4. Преобразование Бокса–Кокса 6
Задание 5. Восстановление пропусков 8
Задание 6. Качество данных до и после обработки 9
Заключение 10

Введение

Цель работы — исследовать аномальные наблюдения, провести очистку и оценить восстановление пропущенных значений средствами R. Выполнены одномерная, двумерная и многомерная диагностика выбросов, анализ категориальных сочетаний и преобразование Бокса–Кокса по индивидуальному заданию.

Вариант 7 задаёт набор Stack Overflow Developer Survey 2011–2022. Копия CSV за 2022 год из архива Kaggle содержит посторонние двоичные данные после анкеты с идентификатором около 68 810. Для расчётов взят оригинальный выпуск с 73 268 анкетами.

Задание 1. Подготовка данных

Выбраны 9 133 профессиональных разработчика из США с полной занятостью. Ограничение одной страной уменьшает неоднородность рынков труда. Годовая компенсация измеряется в долларах США, признаки опыта — в годах.

Значения стажа «менее 1 года» и «более 50 лет» заменены на 0,5 и 51 соответственно. Для годовой компенсации допустимы значения от 1 доллара, для стажа программирования — от 0 до 51 года, для опыта работы — от 0 до 100 лет. Нечисловые значения и записи вне диапазона переводятся в пропуски. Возраст с ответом «предпочитаю не сообщать» учитывается как недоступный.

Листинг 1.1 — Преобразование и проверка числовых значений

```r
parse_number <- function(values) {
  values[values %in% "Less than 1 year"] <- "0.5"
  values[values %in% "More than 50 years"] <- "51"
  suppressWarnings(as.numeric(values))
}
invalid_number <- function(values, lower, upper = Inf) {
  number <- parse_number(values)
  !is.na(values) &
    (!is.finite(number) | number < lower | number > upper)
}
```

Таблица 1.1 — Пропуски и нарушения числовых ограничений

Признак	Пропуски	Нарушения
Годовая компенсация	1 556	0
Общий стаж программирования	28	0
Профессиональный стаж программирования	304	0
Опыт работы	2 829	0

Задание 2. Диагностика числовых выбросов

Для одномерной проверки использованы логарифмы 7 577 положительных компенсаций. Правило Тьюки отметило 572 наблюдения. Критерий Граббса из `outliers` выделил нижнее крайнее значение, соответствующее 36 долларам в год. Получено $G \approx 8{,}871$ и $p < 2{,}2 \cdot 10^{-16}$. Интерпретация критерия зависит от приближения распределения логарифмов нормальным.

Листинг 2.1 — Критерий Граббса и правило Тьюки

```
income <- prepared |>
  filter(!is.na(ConvertedCompYearly)) |>
  transmute(
    ResponseId, income = ConvertedCompYearly,
    log_income = log(income)
  )
grubbs_result <- outliers::grubbs.test(income$log_income)
tukey_values <- boxplot.stats(income$log_income)$out
income <- mutate(
  income, box_flag = log_income %in% tukey_values
)
```

Для двумерной проверки составлен вектор $\boldsymbol{x}_i$ из профессионального стажа и логарифма компенсации. Квадрат расстояния Махаланобиса вычислялся относительно вектора средних $\boldsymbol{\mu}$ и выборочной ковариационной матрицы $\boldsymbol{S}$:

$$d_i^2 = (\boldsymbol{x}_i - \boldsymbol{\mu})^T \boldsymbol{S}^{-1} (\boldsymbol{x}_i - \boldsymbol{\mu}).$$

Кандидаты выделены по правилу $d_i^2 > \chi^2_{2;\,0{,}99}$ при уровне значимости $\alpha = 0{,}01$. Диаграмма `mahalanobis_method` из `OutliersLearn` дополняет числовую проверку.

Листинг 2.2 — Отметки по расстоянию Махаланобиса

```
pair_values <- as.data.frame(
  select(paired, experience, log_income)
)
alpha <- 0.01
paired$d2 <- mahalanobis(
  pair_values, colMeans(pair_values), cov(pair_values)
)
paired$flagged <- paired$d2 > qchisq(1 - alpha, df = 2L)
```

В многомерный анализ добавлен общий стаж программирования. Пакет `HDoutliers` ищет необычно большие расстояния до ближайшего соседа по верхнему хвосту распределения этих расстояний.

Листинг 2.3 — Поиск многомерных выбросов по ближайшим соседям

```
numeric_values <- as.matrix(select(multivariate, -ResponseId))
hd_positions <- HDoutliers::HDoutliers(numeric_values)
hd_cases <- multivariate[hd_positions, , drop = FALSE]
```

Таблица 2.1 — Число наблюдений по методам диагностики

Метод	Полных строк	Отмечено
Правило Тьюки	7 577	572
Расстояние Махаланобиса	7 558	364
Ближайшие соседи в `HDoutliers`	7 554	3 248

Доля отметок `HDoutliers` составляет 43,0 %. Методы работают с разными признаками и порогами. Высокая доля отметок в этом наборе показывает, что применение единого правила удаления сильно изменило бы состав выборки. Отмеченные значения сохранены как кандидаты для предметной проверки.

Задание 3. Гиперграфовый анализ

Вершинами гиперграфа служат анкеты с известными возрастом, образованием и форматом работы. Анкеты с одинаковыми значениями одного или двух фиксированных признаков образуют гиперребро. Для выпуска 2022 года сохраняются рёбра с поддержкой не менее 50 анкет.

По формулам (4.4)–(4.6) методических указаний внутри каждого ребра подсчитываются частоты $S(a)$ значений свободного признака. При k наблюдаемых категориях вычисляются средняя частота, разброс и стандартизованное отклонение:

$$\mu = \frac{\sum_a S(a)}{k}, \quad \sigma = \frac{\sqrt{\sum_a (S(a) - \mu)^2}}{k}, \quad D(a) = \frac{S(a) - \mu}{\sigma}.$$

При нулевом разбросе признак в этом ребре пропускается. Редкими считаются значения с $D(a) < -2$.

Листинг 3.1 — Проверка редкости в одном гиперребре

```
counts <- table(observed)
average <- mean(counts)
spread <- sqrt(sum((counts - average)^2)) / length(counts)
if (spread == 0) {
  next
}
deviation <- (as.numeric(counts[observed]) - average) / spread
selected <- deviation < threshold
```

В контрольном примере из методических указаний получено шесть рёбер. Для записи № 3 в ребре молодых владельцев автомобилей у категории «седан» вычислено $D = -\sqrt{2}$.

Листинг 3.2 — Построение гиперграфа по трём признакам анкеты

```
categorical <- prepared |>
  select(ResponseId, Age, EdLevel, RemoteWork) |>
  filter(if_all(everything(), ~ !is.na(.x)))
hypergraph <- hypergraph_outliers(
  as.data.frame(select(categorical, -ResponseId)),
  categorical$ResponseId, 50L, -2
)
n_distinct(hypergraph$anomalies$id)
```

В исследуемой группе из 8 995 полных анкет построено 65 рёбер. Получены 2 094 отметки по сочетаниям анкеты и контекста. После объединения отметок выявлена 951 уникальная анкета. Например, среди 1 011 анкет с незаконченным высшим образованием у возраста менее 18 лет получено $D \approx -3{,}31$. Редкость сочетания зависит от контекста гиперребра.

Задание 4. Преобразование Бокса–Кокса

Преобразование для положительной годовой компенсации x реализовано по § 4.3.5 ГОСТ Р ИСО 16269-4-2017 без сдвига. Использована форма, непрерывная по параметру λ при $\lambda = 0$:

$$y_\lambda(x) = \begin{cases} \dfrac{x^\lambda - 1}{\lambda} & \lambda \neq 0 \\ \ln(x) & \lambda = 0 \end{cases}.$$

Параметр выбран максимизацией профильного логарифмического правдоподобия на отрезке $[-2, 2]$ с поправкой Якобиана:

$$\ell(\lambda) = -\frac{n}{2}\ln\left(s_\lambda^2\right) + (\lambda - 1)\sum_{i=1}^{n}\ln(x_i),$$

где s_λ^2 — средний квадрат отклонений преобразованных значений от их среднего. Вычисление $x^\lambda - 1$ через `expm1` уменьшает потерю точности вблизи нулевого параметра.

Листинг 4.1 — Оценка параметра и применение преобразования

```
optimum <- optimize(
  box_cox_likelihood, c(-2, 2),
  values = income$income, maximum = TRUE
)
lambda <- optimum$maximum
transformed_income <- box_cox(income$income, lambda)
limits <- box_limits(transformed_income)
```

На 7 577 компенсациях получено $\lambda \approx -0{,}02838$. По графическому критерию § 4.4, формула (8), использованы границы $Q_1 - k \cdot \mathrm{IQR}$ и $Q_3 + k \cdot \mathrm{IQR}$, где $k = 1{,}5$, а $\mathrm{IQR} = Q_3 - Q_1$. Границы на преобразованной шкале составили 9,2066 и 10,9825. За ними оказалось 571 наблюдение.

Диаграммы Q–Q на рисунке 4.1 сравнивают эмпирические и теоретические нормальные квантили. У панелей разные вертикальные шкалы, поскольку после преобразования меняются единицы и диапазон значений.

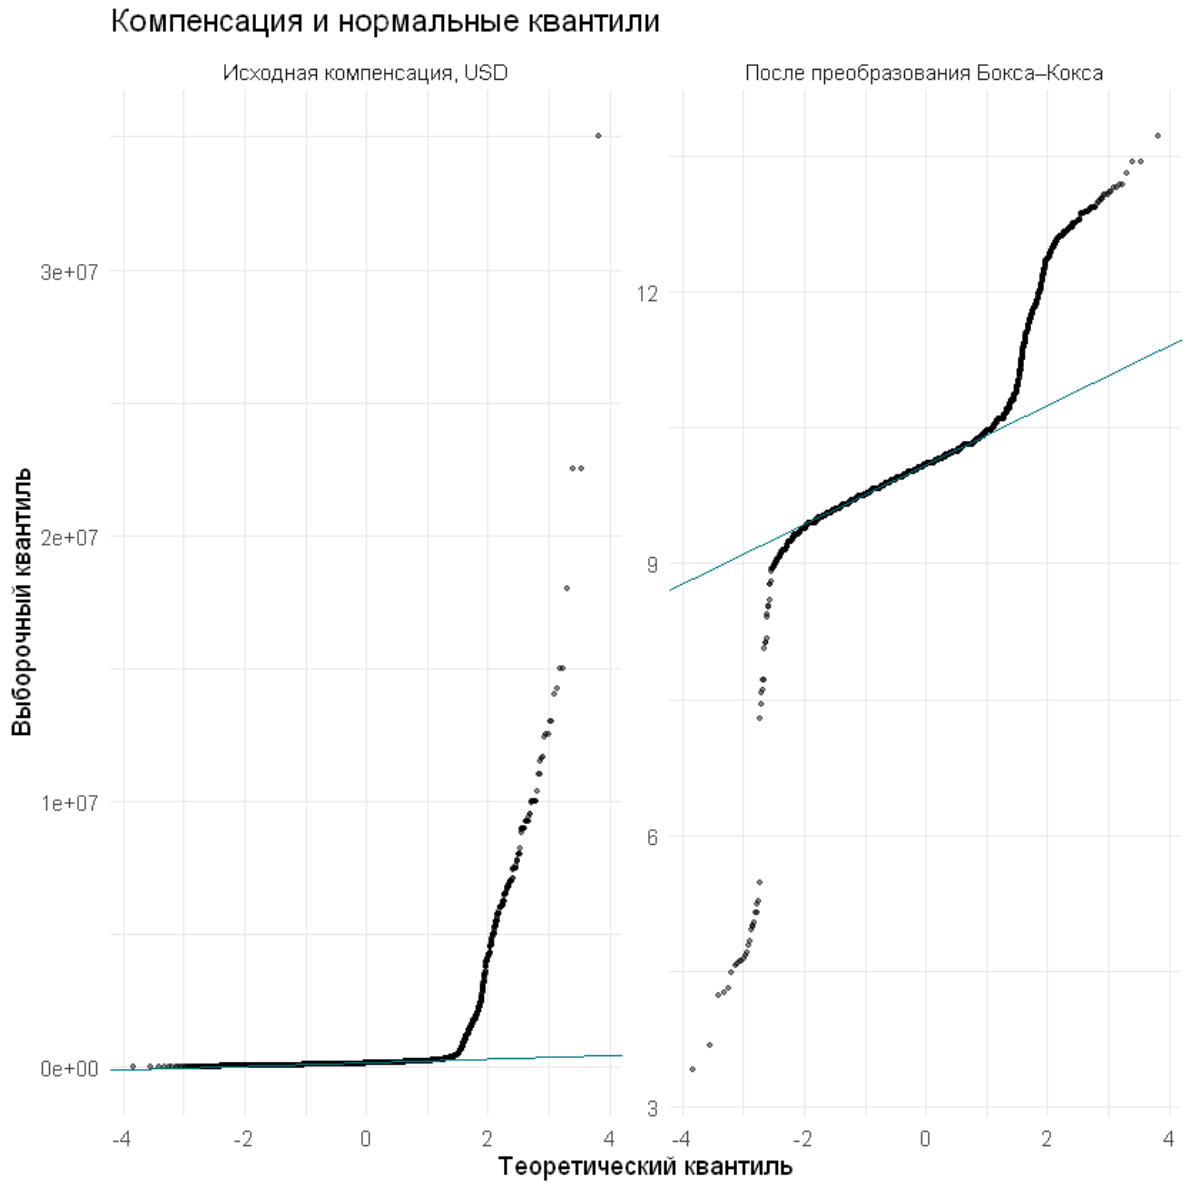


Рисунок 4.1 — Диаграммы Q–Q до и после преобразования Бокса–Кокса

Корреляция выборочных и теоретических квантилей выросла с 0,4645 до 0,8515. После преобразования точки в средней части ближе к прямой. Отклонения в хвостах сохраняются, поэтому преобразование улучшает форму распределения лишь частично.

Задание 5. Восстановление пропусков

Восстанавливался логарифм годовой компенсации вместе с тремя числовыми признаками стажа. Сравнивались пять заполнений методом сопоставления предсказанных средних (PMM) из `mice` и пять заполнений методом бутстрэп-EM из `Amelia`. При PMM пропуск заполняется наблюдённым значением из числа записей с близким прогнозом. Для проверки скрыты 757 известных компенсаций (около 10 %). Прогнозом служит медиана пяти заполнений, а базовой оценкой — медиана остальных наблюдений.

Средняя абсолютная ошибка вычислялась в логарифмической шкале:

$$\mathrm{MAE} = \frac{1}{m}\sum_{i=1}^{m}|\hat{y}_i - y_i|,$$

где $m = 757$, y_i — скрытое значение, $\hat{y}_i$ — восстановленное.

Листинг 5.1 — Маскирование компенсаций для проверки восстановления

```
set.seed(704)
known <- which(!is.na(imputation_data$log_income))
holdout <- sample(known, size = floor(0.1 * length(known)))
masked <- imputation_data
masked$log_income[holdout] <- NA_real_
truth <- imputation_data$log_income[holdout]
baseline <- mean(abs(
  median(masked$log_income, na.rm = TRUE) - truth
))
```

Листинг 5.2 — Заполнение маскированной выборки двумя методами

```
pmm <- mice::mice(
  masked, m = 5, method = "pmm", maxit = 5, seed = 704,
  printFlag = FALSE
)
pmm_tables <- as.list(mice::complete(pmm, action = "all"))
set.seed(704)
bounds <- rbind(c(2, 0, 51), c(3, 0, 51), c(4, 0, 100))
em <- Amelia::amelia(
  masked, m = 5, bounds = bounds,
  empri = 0.01 * nrow(masked), p2s = 0
)
em_tables <- em$imputations
```

Таблица 5.1 — Ошибка на скрытых значениях компенсации

Метод	Скрыто	MAE
Медиана наблюдённых значений	757	0,5207
`mice`, сопоставление предсказанных средних	757	0,5632
`Amelia`, бутстрэп-EM	757	0,7263

Медиана дала наименьшую ошибку для точечного прогноза. Среди методов множественной импутации меньшую ошибку дал `mice`. Он использован для пяти заполнений исходной таблицы. Оценки регрессии логарифма компенсации по стажу объединены по правилам Рубина средствами `mitools`.

Листинг 5.3 — Объединение регрессий по пяти заполнениям

```
completions <- impute(imputation_data, chosen, 705L)
analyses <- with(
  mitools::imputationList(completions),
  lm(log_income ~ professional_years + coding_years +
       work_years)
)
combined <- mitools::MIcombine(analyses)
summary(combined)
```

Таблица 5.2 — Объединённые коэффициенты модели логарифма компенсации

Признак	Оценка	Интервал 95 %
Профессиональный стаж	0,0189	[0,0102; 0,0275]
Общий стаж программирования	0,0041	[−0,0015; 0,0096]
Опыт работы	−0,0125	[−0,0192; −0,0058]

Интервалы описывают условные связи в этой выборке. Проверка со случайным маскированием характеризует восстановление известных ответов. Механизм появления исходных пропусков может отличаться.

Задание 6. Качество данных до и после обработки

Таблица 6.1 сопоставляет исходную выборку и одну из полных реализаций `mice`. Программно проверено отсутствие пропусков во всех пяти реализациях и сохранение исходных наблюдённых компенсаций.

Листинг 6.1 — Проверка полноты таблиц и исходных компенсаций

```
finished <- completions[[1L]]
observed_income <- !is.na(imputation_data$log_income)
full_tables <- vapply(
  completions, function(data) !anyNA(data), logical(1)
)
stopifnot(
  all(full_tables),
  identical(
    finished$log_income[observed_income],
    imputation_data$log_income[observed_income]
  )
)
```

Таблица 6.1 — Сопоставление исходных и обработанных данных

Показатель	**До**	**После**
Число анкет	9 133	9 133
Анкеты без идентификатора	0	0
Повторные идентификаторы	0	0
Пропуски в четырёх числовых полях	4 717	0
Непригодные числовые значения	0	0
Недоступные ответы в трёх категориальных полях	140	140

Годовая компенсация была известна в 7 577 анкетах. Восстановлено 1 556 компенсаций, а медиана изменилась со 146 000 до 145 000 долларов США. Категориальные пропуски сохранены. Это оставляет видимыми ограничения покрытия для анализа гиперграфа.

Заключение

Числовая диагностика показала зависимость числа отмеченных анкет от пространства признаков и выбранного порога. Гиперграфовый метод выделил 951 анкету с редкими сочетаниями. Преобразование Бокса–Кокса улучшило согласованность квантилей с нормальным распределением. Для числовой таблицы заполнено 4 717 пропусков, а объединение пяти результатов позволило учесть неопределённость заполнения при оценке коэффициентов регрессии.