ЛАБОРАТОРНАЯ РАБОТА № 4.
Оценка качества, очистка и предобработка данных

Цель работы – получить навыки оценки качества, очистки и предобработки данных с использованием средств языка программирования R.

4.1. Выявление аномалий в данных

Существует общепринятая формулировка определения аномального наблюдения (или выброса), представленная в [1] ГОСТ Р ИСО 16269-4-2017: «Выбросы – это данные среди исходных результатов измерений (или данные, полученные из результатов измерений), которые настолько отклоняются от сопоставимых данных, что признаются несовместимыми».

Одно из первых определений было предложено Д.М. Хокинсом в 1980 г. «Выброс – это результат наблюдения, который настолько сильно отличается от остальных наблюдений, что возникает подозрение о порождении его другим механизмом» [2].

Под выбросом обычно понимают наблюдение, которое отличается от основной части данных и несовместимо с остальными данными [3].

Также можно определить выбросы как нетипичные или редкие значения, которые существенно отклоняются от распределения остальных выборочных данных. Эти данные могут отражать истинные свойства изучаемого явления, а могут быть связаны с ошибками измерения или аномальными явлениями [4].

Резко выделяющиеся наблюдения могут являться результатом действия нескольких различных механизмов или причин. Выделяют две основные группы причин появления выбросов: аномальные наблюдения, являющиеся результатом ошибки в изучаемых данных, либо выбросы как результат появления редкого события [2].

В результате индивидуальной ошибки или по причине неточности человеческих действий в процессе сбора, регистрации и ввода данных появляются выбросы как результат случайной ошибки. При наличии

возможности доступа к первичной информации данные такой природы необходимо исправить путем пересмотра исходных документов. В случае, если искаженные данные не могут быть скорректированы, их необходимо исключить, поскольку они не являются элементами наблюдаемой генеральной совокупности.

Выбросы как результат преднамеренного искажения информации возникают, когда участники исследования специально сообщают недостоверную информацию. Они сознательно пытаются повредить исследованию или руководствуются другими побуждениями. В социальных исследованиях зачастую данные носят очень личный характер (заработная плата, уровень образования, социальный статус, религиозная принадлежность, вредные привычки и т.п.). Когда большинство участников исследования сообщают недостоверные сведения, то правдивые данные нескольких человек могут оказаться выбросами.

Выбросы как результат ошибки получения выборки возможны, если происходит ошибочное принятие нескольких результатов наблюдения из другой генеральной совокупности. Например, среди учащихся могут встретиться одаренные или, наоборот, умственно отсталые люди, данные о которых, в зависимости от цели исследования, могут оказаться выбросами. Такие наблюдения должны быть исключены из выборки, поскольку не являются элементами целевой генеральной совокупности.

В ряде исследований анализируемые данные могут содержать аномальные наблюдения, которые являются абсолютно достоверными и содержат совершенно новую, ранее не наблюдавшуюся закономерность или явление, и поэтому необходим анализ, выявление причинно-следственных связей, приведших к появлению резко выделяющегося наблюдения, и, возможно, дальнейшее изучение обнаруженного редкого явления.

Присутствие единственного аномального наблюдения в анализируемых данных влечет за собой ряд негативных последствий:

- смещение или искажение оценок параметров распределений;

- увеличение дисперсии ошибок (оценки коэффициентов регрессии, к примеру, которые минимизируют сумму квадратов ошибок, очень чувствительны к наличию выбросов);
- ложные выводы и заключения [5].

Для исключения негативных последствий, связанных с наличием аномальных наблюдений в исследуемых данных проводится процесс их выявления и последующего удаления, либо их изменения, при наличии данной возможности. Также по результатам выявления аномальных наблюдений можно указать на необходимость проведения повторного, но уже более тщательного и детального, процесса получения информации с целью избежать различных ошибок, связанных со сбором, регистрацией и обработкой данных.

4.2. Методы выявления выбросов

Процесс выявления аномальных наблюдений представляет собой непростую задачу, при решении которой требуется обработка больших объемов статистической информации.

Выбор метода выявления резко выделяющихся наблюдений зачастую определяется различными факторами, в том числе, такими как характер исследуемых процессов, размерность задачи и тип анализируемых данных [6].

Существует несколько видов данных, используемых при проведении различных исследований и работ:

- номинальные данные (например, тип болезни или признак: “болен” –“не болен”);
- порядковые данные (например, самочувствие: “плохое” – “удовлетворительное” – “хорошее”);
- непрерывные данные (например, давление, температура).

В реальном исследовании обычно присутствуют данные всех типов. Качественные данные (номинальные и порядковые) иногда называют также категориальными или дискретными данными [7, 8].

Методы выявления выбросов можно разделить на классы в зависимости от понятий, на которых они основаны, их классификация представлена на рисунке 4.1.

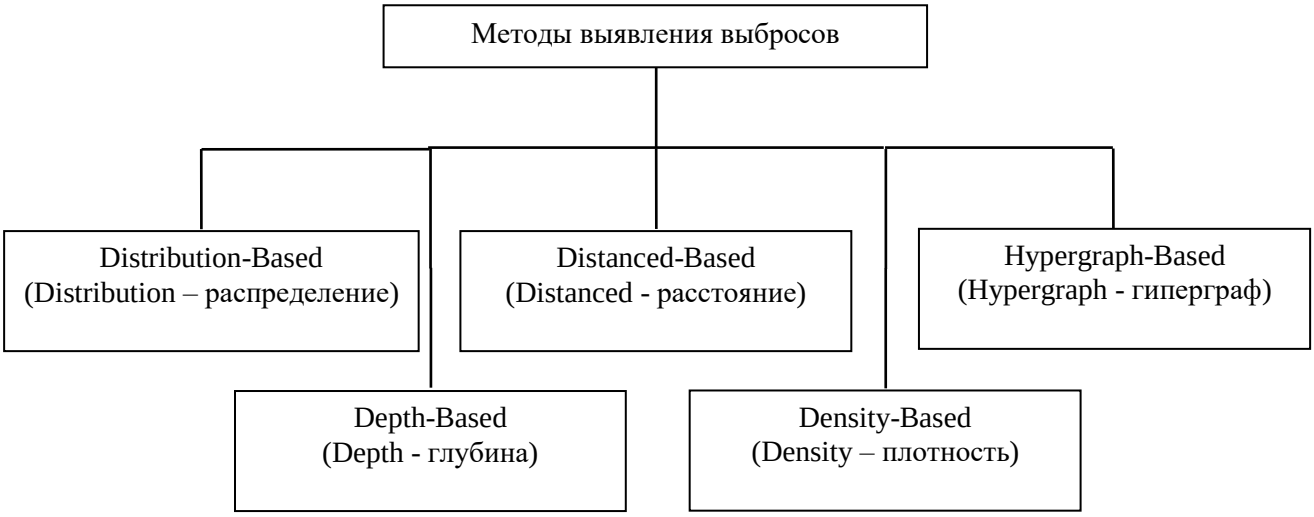


Рисунок 4.1. Классификация методов выявления выбросов в зависимости от основополагающих понятий

Класс методов выявления аномальных наблюдений, известный в англоязычной литературе под названием Distribution-Based методы, базируется на предположении о принадлежности наблюдаемых случайных величин определенному закону распределения. Чаще всего в качестве предполагаемого закона рассматривается нормальный закон распределения.

Статистические методы выявления выбросов в одномерной выборке описаны на стр. 543-568 в учебнике [9] Кобзарь А.И. Прикладная математическая статистика. Для инженеров и научных работников.

Выдвигается нулевая гипотеза H_0, которая состоит в том, что наблюдаемые случайные величины $\xi_1, \xi_2, \ldots, \xi_n$ независимы и имеют одинаковое распределение $N(\mu,\sigma^2)$. Чтобы дать «альтернативу с учетом аномальных наблюдений» для гипотезы H_0, Граббсом и Диксоном были развиты две главные модели [10]. В первой модели предполагается, что w из n величин (неизвестно какие) отличаются от остальных $n-w$ величин параметром сдвига: имеют математические ожидания $\mu+\lambda_i\sigma$ $(\lambda_i \neq 0, i=\overline{1,w})$ и общую дисперсию σ^2. Во второй модели эти w величин отличаются

параметром масштаба: имеют одинаковые математические ожидания μ и дисперсии $\lambda_i^2\sigma^2$, $(\lambda_i^2 > 1, i = \overline{1,w})$.

В данных моделях существует ряд вариантов, зависящих от степени информации о параметрах μ и σ^2, также в зависимости от сдвигов в разных направлениях, т.е. рассматриваются w минимальных или w максимальных результатов наблюдений, возможно дальнейшее исследование. Для каждого из возможных случаев существует по крайней мере одна статистика [10-12]. Зачастую распределения статистик критериев типа Граббса существенно зависят от истинного закона распределения наблюдаемой случайной величины. Поэтому, если предположения о нормальности нарушаются, использовать эти критерии нельзя.

Проблему аномальных наблюдений в многомерном нормальном случае исследовал Уилкс, используя в качестве основной статистики для проверки гипотезы об отсутствии выбросов среди наблюдений m-мерных случайных векторов $\vec{\xi}_1, \vec{\xi}_2, \ldots, \vec{\xi}_n$, отношение определителей

$$r_l = \frac{|B_l|}{|B|},$$

где $B = (b_{ij})_{m\times m}$ – матрица, составленная из элементов

$$b_{ij} = \sum_{q=1}^{n}(x_{iq} - \overline{x_i})(x_{jq} - \overline{x_j}), \qquad (4.1)$$

$\overline{x}_i = \dfrac{\sum_{p=1}^{n} x_{ip}}{n}$ – выборочное среднее i-ой компоненты случайных векторов; $B_l = (b_{ijl})_{m\times m}$ – матрица, элементами b_{ijl} которой являются суммы аналогичные (4.1) с пропущенным l-ым наблюдением $(l = \overline{1,n})$. Известно, что соответствующая выборочному значению r_l статистика имеет бета-распределение $B\left(\frac{1}{2}(n-m-1), \frac{1}{2}m\right)$. Наблюдение, отвечающее наименьшему значению r_l является первым кандидатом в аномальные [10].

К статистическим относятся также методы, основанные на использовании регрессионных моделей, в том числе, метод уменьшения остаточной дисперсии [13]. Имеющаяся информация представляется в виде таблицы наблюдений (таблица 4.1), где $Y_1, Y_2, \ldots, Y_m$ – объясняемые или результирующие переменные, а $X_1, X_2, \ldots, X_l$ – данные, определяющие значения результирующих переменных.

Таблица 4.1. Таблица наблюдений

Объект наблюдения	Y_1	Y_2	…	Y_m	X_1	X_2	…	X_l
1	y_{11}	y_{12}	…	y_{1m}	x_{11}	x_{12}	…	x_{1l}
2	y_{21}	y_{22}	…	y_{2m}	x_{21}	x_{22}	…	x_{2l}
…	…	…	…	…	…	…	…	…
n	y_{n1}	y_{n2}	…	y_{nm}	x_{n1}	x_{n2}	…	x_{nl}

В соответствии с алгоритмом проведения множественного регрессионного анализа по данным таблицы 4.1 для каждой объясняемой переменной строится линейная регрессионная модель вида

$$\tilde{Y}_i = a_{0i} + a_{1i}X_1 + \cdots + a_{pi}X_p,\ i = \overline{1, m},\ p \le l, \qquad (4.2)$$

где $a_{0i}, a_{1i}, \ldots, a_{pi}$ – коэффициенты регрессии. При построении моделей необходимо произвести поиск наилучших наборов переменных, входящих в уравнение регрессии. Требование, предъявляемое к модели – адекватность по критерию Фишера.

Аномальные наблюдения определяются по тому вкладу, который они вносят в величину остаточной дисперсии $S^2_{ост}$, вычисляемую по формуле

$$S^2_{ост} = \frac{\sum_{j=1}^{n}\left(y_{ij} - \tilde{y}_{ij}\right)^2}{n - p - 1},\ i = \overline{1, m}.$$

Вклад каждого наблюдения в величину $S^2_{ост}$ можно определить, исключая по отдельности из набора наблюдений, участвующих в расчете регрессионной модели, включенные в него наблюдения. Наблюдение, устранение которого приводит к наибольшему уменьшению величины остаточной дисперсии,

считается аномальным. Остановить исключение наблюдений можно по условию

$$\left|Y_i - \widetilde{Y}_i\right| \le S_i,\ i = \overline{1, m},$$

где S_i – уровень достоверности наблюдаемого значения i-ой переменной, т. е. максимально возможное отклонение между рассчитанным значением по статистической модели (4.2) и фактическим значением i-ой объясняемой переменной.

Distribution-Based методы имеют ряд серьезных ограничений, сужающий область их применения при проведении процесса выявления аномальных наблюдений в статистических данных [14]. Поскольку методы основаны на конкретной функции распределения, в случае, когда закон распределения заранее не известен, необходимо проводить проверку анализируемых данных на подчинение какому-либо закону, что требует дополнительных временных затрат. Также при увеличении размерности данных выбор многомерного распределения становится затруднительным.

Следующим шагом в изучении проблемы выявления резко выделяющихся наблюдений стало появление Depth-Based методов, в которых устранены некоторые недостатки статистических методов.

Класс Depth-Based методов базируется на некотором определении глубины, данные в этих методах организуются в пространственные слои и предполагается, что в неглубоких слоях появление выброса более вероятно, чем в глубоких [15-16]. Данные методы не сталкиваются с проблемой определения распределения данных и теоретически позволяют обрабатывать многомерные данные. Но они оказались практически не приемлемыми для данных, размерность которых превышает четырех, и фактически Depth-Based методы дают приемлемые результаты при анализе наблюдений, размерность которых равна двум.

При исследовании данных высокой размерности наиболее приемлемо применение Distanced-Based методов, основанных на вычислении расстояния

между объектами данных. В качестве меры расстояния между любой парой объектов наблюдений обычно выбирается евклидово расстояние, либо расстояние Махаланобиса.

Для обработки данных высокой размерности также возможно применение Density-Based методов [15]. Данная группа методов основана на анализе плотности данных в пространственных проекциях. Объект наблюдения определяется как аномальный, если в некоторой пространственной проекции данных он присутствует в области с аномально низкой плотностью.

Для определения проекций с аномально низкой плотностью область принимаемых значений каждой из m переменных (свойств), характеризующих объекты наблюдения, делится на φ равных областей путем установления сетки. При пересечении сетки по d различным измерениям ($d<m$) образуется d-мерный куб или d-мерная пространственная проекция. В качестве меры плотности данных в d-мерном кубе может служить коэффициент разброса, вычисляемый по формуле

$$R(d)=\frac{n_d - n\cdot f^d}{\sqrt{n\cdot f^d\cdot(1-f^d)}},$$

где n – количество объектов наблюдения; n_d – количество проекций объектов наблюдения в d-мерном кубе; $f^d=\frac{1}{\varphi^d}$ – вероятность попадания проекции объекта наблюдения в какой-либо d-мерный куб.

Коэффициент $R(d)>0$ означает, что в рассматриваемом d-мерном кубе плотность точек больше ожидаемой, а значит объекты, проекции которых присутствуют в этой области, не являются выбросами. Коэффициент $R(d)=0$ свидетельствует о средней плотности данных, и лишь отрицательный коэффициент $R(d)<0$ указывает на низкую плотность точек в рассматриваемой области, и объекты, проекции которых присутствуют в этой области, являются кандидатами на выбросы.

Задача определения выбросов в Density-Based методах сводится к нахождению проекций данных с наиболее отрицательными коэффициентами разброса

$$\begin{aligned} R(d) &\to min, \\ R(d) &< 0. \end{aligned} \tag{4.3}$$

Для решения оптимизационной задачи (4.3) можно использовать прямой алгоритм brute force, который заключается в простом переборе всевозможных d-мерных пространственных проекций данных и вычислении плотности точек в образующихся d-мерных кубах. При высокой размерности данных использование этого алгоритма не является целесообразным, поскольку требует больших временных затрат. Более эффективным является генетический алгоритм, в котором в качестве особи рассматривается строковое представление d-мерной проекции.

Density-Based методы являются устойчивыми к наличию пропусков в данных, но также, как и Distribution-Based, и Distanced-Based методы предполагают обработку лишь непрерывно изменяющихся переменных. Данные методы практически неприменимы для статистических данных, измеренных в дискретной шкале.

Задача нахождения аномальных наблюдений в статистических данных, измеренных в дискретной шкале, решается при помощи Hypergraph-Based метода, который базируется на построении гиперграфа и вычислении отклонений по изучаемым свойствам исследуемых объектов наблюдений относительно сформированных гиперребер [17].

4.3. Алгоритм Hypergraph-Based метода выявления аномальных наблюдений в многомерной выборке

Density-Based методы являются устойчивыми к наличию пропусков в данных, но также, как и Distribution-, и Distanced-Based методы предполагают обработку лишь непрерывно изменяющихся переменных. Для категориальных переменных хорошим индикатором аномальных данных могут стать измерения,

проведенные для частоты появлений, но далеко не всегда. С увеличением размерности и количества возможных значений каждой переменной, потребуется немало времени, чтобы вычислить частоту появления различных комбинаций. Более того, реальные данные могут содержать пропуски. В [17] предлагается возможное решение задачи выявления выбросов в категориальных данных с помощью Hypergraph-based метода, основанного на построении графа.

Основной алгоритм определения аномальных наблюдений при помощи Hypergraph-Based метода состоит из нескольких шагов:

1. Создание иерархии гиперграфа.
2. Формирование векторов и матриц, содержащих сведения о значении свойств наблюдений, входящих в гиперребро.
3. Этап обнаружения выбросов.

На первом этапе имеется набор данных $X = (X_i), i = \overline{1,n}$, где $X_i = (x_{ij}), j = \overline{1,m}$ представляет собой объект наблюдения, определяются входные параметры метода: минимальное число элементов в гиперребре и отрицательный параметр θ.

Каждое наблюдение $X_i = (x_{ij}), j = \overline{1,m}$, $i = \overline{1,n}$ является вершиной гиперграфа, а значения $x_{11}, x_{12}, \ldots, x_{1m}$; $x_{21}, x_{22}, \ldots, x_{2m}$; $\ldots; x_{n1}, x_{n2}, \ldots x_{nm}$ - определяются как набор свойств, характеризующих первую, вторую и последующие вершины.

Для каждой вершины i, $i = \overline{1,n}$ гиперграфа H формируется вектор свойств M_i, $i = \overline{1,n}$, элементами которой являются i–тые наблюдаемые значения исходного набора данных: $M_1 = (x_{11}, x_{12}, \ldots, x_{1m})$, $M_2 = (x_{21}, x_{22}, \ldots, x_{2m})$, …, $M_n = (x_{n1}, x_{n2}, \ldots x_{nm})$.

Объединение вершин гиперграфа в гиперребра осуществляется следующим образом: производится поиск повторяющихся значений по всем объектам наблюдений i, $i = \overline{1,n}$. Сначала определяются комбинации, состоящие из

одного значения, затем - двух, данная процедура выполняется до поиска m-1 числа повторяющихся значений. Если число вершин, у которых присутствует одинаковое свойство или набор свойств, больше минимального числа элементов L, то данные вершины объединяются в гиперребро.

Для каждого сформированного гиперребра, строится матрица $G = (g_{ij}), i = \overline{1,s},\ j = \overline{1,m-1},$ размеры которой определяются числом вершин s, входящих в рассматриваемое ребро, и размерностью задачи m. Элементами данной матрицы являются элементы вектора $M_i, i = \overline{1,n}$, соответствующие вершине, входящей в гиперребро, и отвечающие тем свойствам, по которым у рассматриваемого гиперребра нет повторяющихся значений.

Гиперграф $H = (V, HE)$ содержит множество вершин V и множество ребер HE. Каждая вершина $v \in V$ соответствует одному объекту наблюдения, а каждое гиперребро $he \in HE$ содержит множество объектов, у которых встречается одно и тоже сочетание значений переменных. Одним из входных параметров метода является минимальное количество появлений возможных комбинаций значений переменных.

Отклонением $Dev_{he}(\vec{x}, A)$ объекта данных $\vec{x}$ по переменной (свойству) A относительно гиперребра he называется величина

$$Dev_{he}(\vec{x}, A) = \frac{S_A^{he}(a_{\vec{x}}) - \mu_{S_A^{he}}}{\sigma_{S_A^{he}}}, \tag{4.4}$$

где

$$\mu_{S_A^{he}} = \frac{1}{\left\|A^{he}\right\|} \sum_{a \in A} S_A^{he}(a), \tag{4.5}$$

$$\sigma_{S_A^{he}} = \frac{1}{\left\|A^{he}\right\|} \sqrt{\sum_{a \in A} \left(S_A^{he}(a) - \mu_{S_A^{he}}\right)^2}, \tag{4.6}$$

$\left\|A^{he}\right\|$ – число различных значений a переменной A, встретившихся у объектов из ребра he; $S_A^{he}(a)$ – количество объектов из ребра he, у которых переменная A принимает значение a; $a_{\vec{x}}$ – значение переменной A у объекта $\vec{x}$.

Значение переменной A объекта данных $\vec{x}$ из ребра he считается выбросом, если соответствующее отклонение меньше пороговой величины θ, т. е. $Dev_{he}(\vec{x}, A) < \theta$ – второй входной параметр, который обычно является отрицательной величиной.

На этапе обнаружения выбросов рассматривается каждое гиперребро и при использовании ранее сформированной матрицы $G = (g_{ij}), i = \overline{1,s}, j = \overline{m-1}$ осуществляется ряд последовательных действий:

1. Для каждой вершины, входящей гиперребро, по каждому свойству (переменной) вычисляются значения $S_A^{he}(a)$, $\mu_{S_A^{he}}$ и $\sigma_{S_A^{he}}$ по формулам (4.5) – (4.6).
2. Вычисляется величина отклонения $Dev_{he}(X_i, A)$ для объекта наблюдения X_i по свойству A относительно гиперребра he.
3. Вычисленные отклонения сравниваются с пороговым значением θ и делается вывод о аномальности либо приемлемости значения свойства исследуемого объекта наблюдений.

Рассмотренный алгоритм можно продемонстрировать на следующем примере: пусть имеется набор данных (таблица 4.2), состоящий из 10 наблюдений по 3 свойствам, характеризующим владельцев автомобилей.

Таблица 4.2. Данные о владельцах автомобилей

Объект наблюдения	Возраст владельца	Тип автомобиля	Уровень дохода
1	средний	седан	низкий
2	средний	седан	высокий
3	молодой	седан	высокий
4	средний	седан	низкий
5	молодой	спортивный	высокий
6	молодой	спортивный	низкий
7	средний	седан	высокий
8	молодой	спортивный	низкий
9	средний	седан	высокий
10	молодой	спортивный	низкий

Число появлений различных комбинаций значений примерно одинаково и представлено в таблице 4.3.

Таблица 4.3. Возможные комбинации значений

№	Комбинация значений	Число появлений
1	(“средний”, “седан”, “низкий”)	2
2	(“молодой”, “спортивный”, “низкий”)	3
3	(“молодой”, “седан”, “высокий”)	1
4	(“молодой”, “спортивный”, “высокий”)	1
5	(“средний”, “седан”, “высокий”)	3

Одним из входных параметров метода является минимальное количество появлений возможных комбинаций значений переменных L. Допустим, что для рассматриваемого примера это количество равно 5. Тогда модель гиперграфа может быть представлена в виде табл. 4.4.

Таблица 4.4. Модель гиперграфа

№ гиперребра	Повторяющаяся комбинация значений	Номера вершин, входящих в гиперребро
1	(“средний”, *, *)	1, 2, 4, 7, 9
2	(“молодой”, *, *)	3, 5, 6, 8, 10
3	(*, “седан”, *)	1, 2, 3, 4, 7, 9
4	(*, *, “низкий”)	1, 4, 6, 8, 10
5	(*, *, “высокий”)	2, 3, 5, 7, 9
6	(“средний”, “седан”, *)	1, 2, 4, 7, 9

Трехмерное изображение сформированного гиперграфа представлено на рис. 4.2.

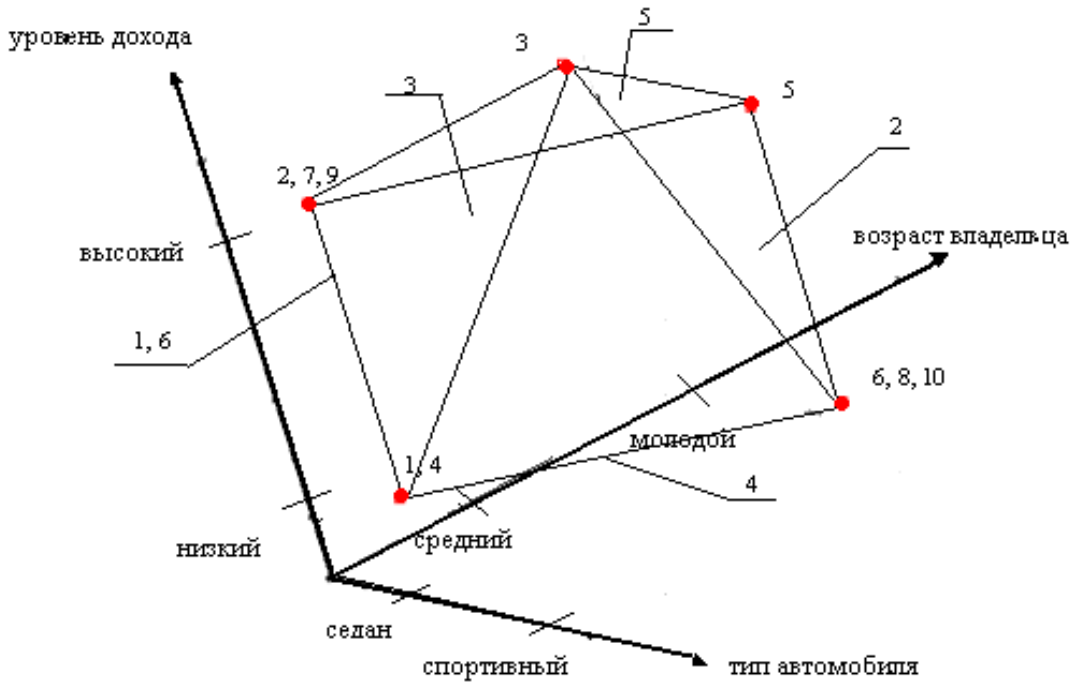


Рисунок 4.2. Гиперграф

Проекции гиперграфа на различные плоскости представлены на рис. 4.3 – 4.5.

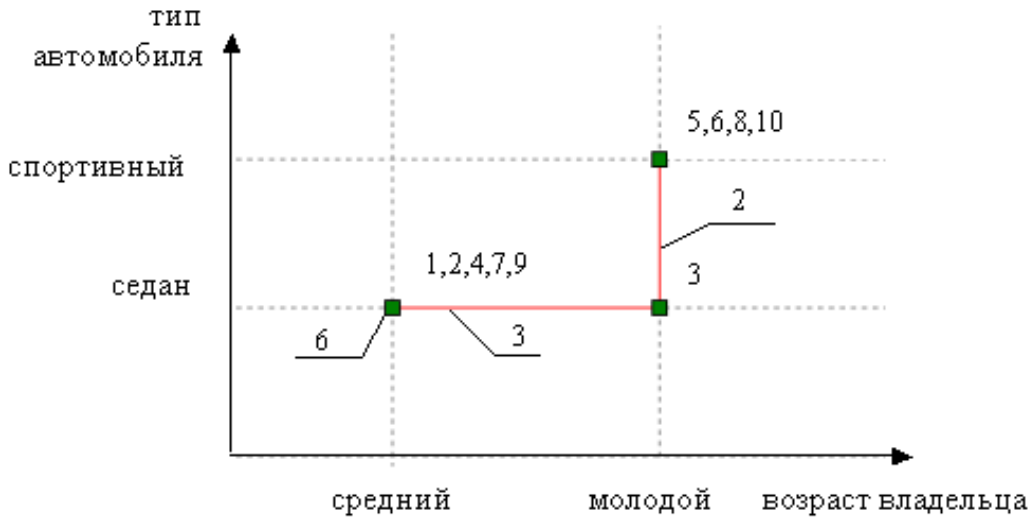


Рисунок 4.3. Проекция гиперграфа по переменным «Возраст владельца», «Тип автомобиля»

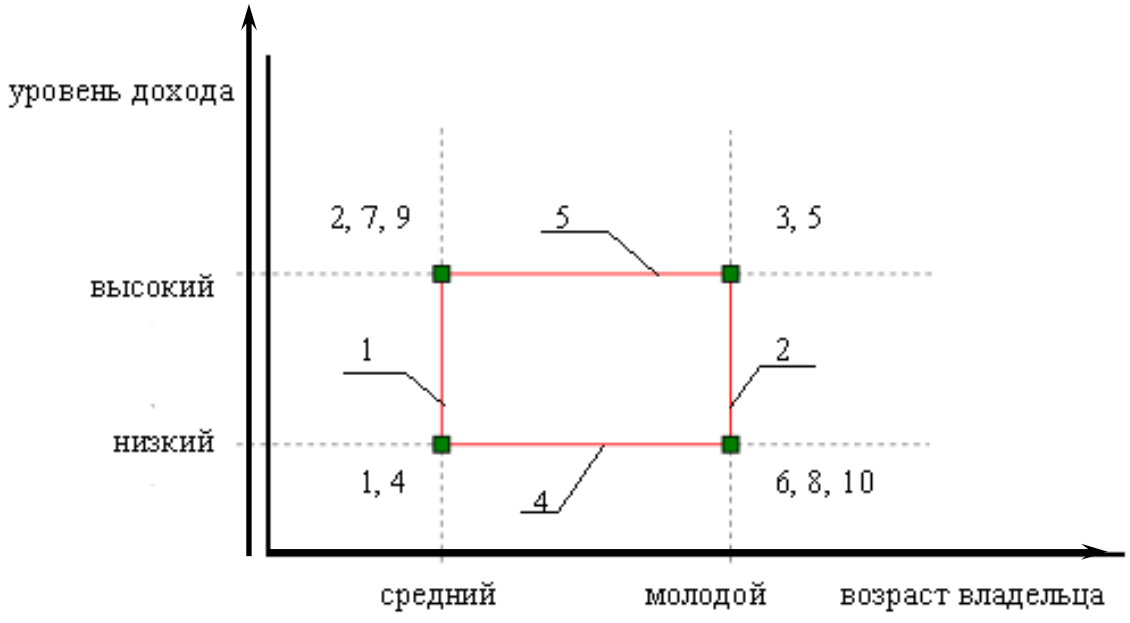


Рисунок 4.4. Проекция гиперграфа по переменным «Возраст владельца», «Уровень дохода»

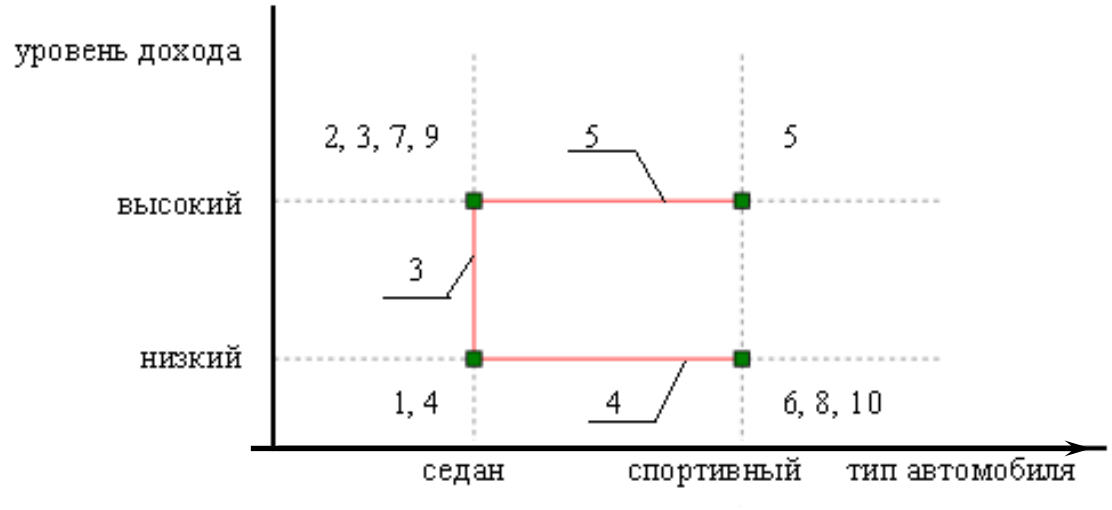


Рисунок 4.5. Проекция гиперграфа по переменным «Уровень дохода», «Тип автомобиля»

В таблице 4.5 представлены отклонения для объектов из второго гиперребра *he* по переменной «Тип автомобиля» (обозначим её *Car*). Число различных значений

$$\| Car^{he} \| = 2,\ \mu_{S_{Car}^{he}} = \frac{1}{2}(1+4) = 2.5,\ \sigma_{S_{Car}^{he}} = \frac{1}{2}\sqrt{(1-2.5)^2 + (4-2.5)^2} \approx 1.06.$$

Таблица 4.5. Отклонения объектов второго гиперребра по переменной «Тип автомобиля»

Вершина	Возраст владельца	Тип автомобиля	Уровень дохода	Отклонение
3	молодой	седан	высокий	-1,42
5	молодой	спортивный	высокий	1,42
6	молодой	спортивный	низкий	1,42
8	молодой	спортивный	низкий	1,42
10	молодой	спортивный	низкий	1,42

На основании полученных результатов значение рассматриваемой переменной (*Car*) у третьего объекта наблюдений можно считать выбросом, который интерпретируется следующим образом: молодые люди обычно выбирают спортивные автомобили, а не автомобили типа “седан” [17].

4.4. Восстановление пропущенных данных

Данные могут отсутствовать по многим причинам, например, участники анкетирования могут забыть ответить на один или более вопросов, отказаться

отвечать на щекотливые вопросы или же утомиться и не закончить заполнение длинной анкеты.

К сожалению, большинство статистических методов рассчитано на то, что вы работаете с полными матрицами, векторами и таблицами данных. В большинстве случаев придется удалить пропущенные данные, перед тем как искать ответ на те вопросы, которые побудили начать исследование.

От пропущенных данных можно избавиться, (1) удаляя наблюдения с такими данными или (2) заменяя пропущенные данные подходящими расчетными значениями.

Методы нахождения и замещения пропущенных значения представлены на рисунке 4.6.

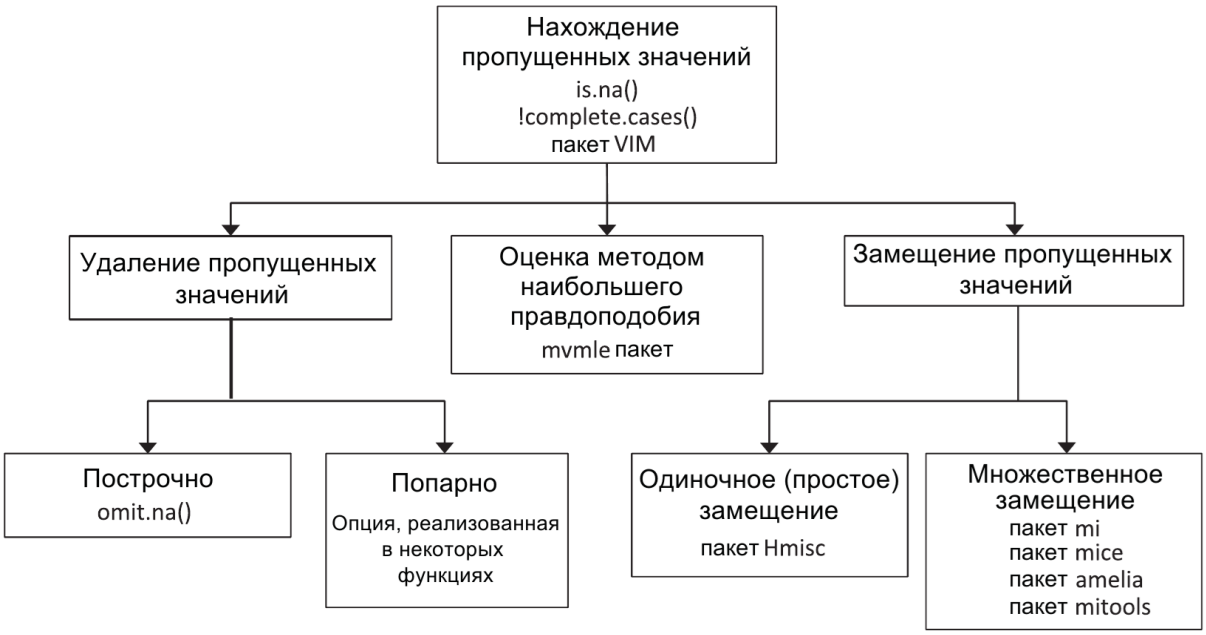


Рисунок 4.6. Методы и библиотеки R для работы с пропущенными данными

В R пропущенные значения обозначаются как NA (нет в наличии – not available), а недопустимые значения – как NaN (не являются числом – not a number). В дополнение символы Inf и –Inf обозначают плюс и минус бесконечность соответственно. Для обнаружения пропущенных, недопустимых и бесконечных значений используются функции is.na(), is.nan() и is.infinite() соответственно. Каждая из них возвращает значения TRUE (правда) и FALSE (ложь).

Функция md.pattern() из пакета mice представляет информацию о пропущенных значениях в табличной форме.

В пакете VIM реализованы многочисленные функции для визуализации структуры пропущенных данных такие, как aggr(), matrixplot() и marginplot().

Функция aggr() графически отображает число наблюдений для каждой отдельной переменной и для каждой комбинации переменных. Функция matrixplot() графически отображает данные по каждой строке. Числовые данные нормализованы так, что они все находятся в интервале [0, 1] и представлены оттенками серого. Чем светлее оттенок, тем более низкому значению он соответствует. По умолчанию пропущенные значения обозначены красным. Команда marginplot() позволяет получить диаграмму рассеяния для двух переменных, где информация о пропущенных значениях представлена на полях.

Более подробную информацию о методах выявления аномальных наблюдений и восстановления пропущенных значений с использованием R можно найти:

- в разделе 8.4. «Необычные наблюдения» [19]
- в разделе 4.3. «Анализ выбросов» [20];
- в главе 15 «Продвинутые методы работы с пропущенными данными» [19];
- в разделе 4.4. «Заполнение пропущенных значений в таблицах данных» [20];
- на сайте CRAN Task View: Missing Data [21].

4.5. Задание на лабораторную работу

1. Подключиться в https://www.kaggle.com/ и скачать данные в формате *.csv в соответствии со своим вариантом (номер варианта соответствует номеру по списку в учебной группе).
2. Провести одномерный, двумерный и многомерный анализ наличия аномальных наблюдений в R с использованием библиотек outliers,

HDoutliers и OutliersLearn.

3. Реализовать алгоритм Hypergraph-Based метод выявления выбросов в многомерных категориальных данных и применить к данным из своего варианта.
4. Реализовать метод выявления выбросов и преобразования данных в соответствии с индивидуальным заданием (таблица 4.6).
5. Провести анализ, выбрать методы восстановления пропущенных значений в R с использованием библиотек mice, amelia, mitools**.**
6. Провести анализ качества данных в R до и после проведения очистки и предобработки данных.
7. Подготовить отчёт по выполненной работе в формате Word/PDF

4.6. Варианты заданий

1. Latest Global Temperatures (https://www.kaggle.com/datasets/csafrit2/latest-global-temperatures)
2. Finance companies in India (https://www.kaggle.com/datasets/anuragbantu/finance-companies-in-india)
3. Black Friday Sales EDA(https://www.kaggle.com/datasets/pranavuikey/black-friday-sales-eda)
4. Football Transfers from 1992/93 to 2021/22 seasons(https://www.kaggle.com/datasets/cbhavik/football-transfers-from-199293-to-202122-seasons)
5. World, Region, Country GDP/GDP per capita (https://www.kaggle.com/datasets/tmishinev/world-country-gdp-19602021)
6. Air Pollution Level (https://www.kaggle.com/datasets/totoro29/air-pollution-level)
7. Stack Overflow Developer Survey 2011-2022 (https://www.kaggle.com/datasets/yasirabdaali/stack-overflow-developer-survey-20112022)
8. Financing Healthcare (https://www.kaggle.com/datasets/programmerrdai/financing-healthcare)
9. Law School Admissions Bar Passage (https://www.kaggle.com/datasets/danofer/law-school-admissions-bar-passage)
10. Vending Machine Sales (https://www.kaggle.com/datasets/awesomeasingh/vending-machine-sales)
11. Global Companies dataset (https://www.kaggle.com/datasets/narayan63/global-companies-dataset)
12. Smoke Detection Dataset (https://www.kaggle.com/datasets/deepcontractor/smoke-detection-dataset)
13. Netflix Data: Cleaning, Analysis and Visualization (https://www.kaggle.com/datasets/ariyoomotade/netflix-data-cleaning-analysis-and-visualization)
14. World Population by Countries Dataset (1960-2021) (https://www.kaggle.com/datasets/kaggleashwin/population-dataset)

15. Online Retails Sale Dataset (https://www.kaggle.com/datasets/rohitmahulkar/online-retails-sale-dataset)
16. Spotify unpopular songs (https://www.kaggle.com/datasets/estienneggx/spotify-unpopular-songs)
17. Chocolate Bar Ratings (https://www.kaggle.com/datasets/evangower/chocolate-bar-ratings)
18. Airbnb Open Data (https://www.kaggle.com/datasets/arianazmoudeh/airbnbopendata)
19. IMDB Movies (https://www.kaggle.com/datasets/totoro29/imdb-movies)
20. Youtube Statistics (https://www.kaggle.com/datasets/advaypatil/youtube-statistics)

Таблица 4.6. Индивидуальное задание

№	Метод
1	Метод GESD «4.3.2 Выборка из нормального распределения» [1].
2	Метод Гринвуда «4.3.3.2 Критерий наличия выбросов Гринвуда» [1].
3	Методы выявления выбросов для логнормального распределения «4.3.4 Выборки не из нормальных распределений» [1].
4	Методы выявления выбросов для распределения экстремальных значений типа I «4.3.4 Выборки не из нормальных распределений» [1].
5	Методы выявления выбросов для распределения Вейбулла «4.3.4 Выборки не из нормальных распределений» [1].
6	Методы выявления выбросов для гамма-распределения «4.3.4 Выборки не из нормальных распределений» [1].
7	Преобразование Бокса-Кокса «4.3.5 Выборка из неизвестного распределения» [1].
8	Критерий Кохрена «4.3.6 Критерий Кохрена для выявления выбросов дисперсий» [1].
9	Модифицированная диаграмма ящик с усами «4.4 Графический критерий выявления выбросов» [1].
10	Выбросы в выборке многомерных наблюдений объема «6.2 Выбросы многомерных данных» [1].
11	Выбросы в линейной регрессии «6.3.3 Обнаружение выбросов по компоненте Y» [1].
12	Выбросы в линейной регрессии «6.3.4 Обнаружение выбросов по компоненте X» [1].
13	Выбросы в линейной регрессии «6.3.5 Обнаружение влияющих наблюдений» [1].

Список литературы

1. ГОСТ Р ИСО 16269-4-2017. Статистическое представление данных. Часть 4. Выявление и обработка выбросов (Statistical methods. Statistical data presentation. Part 4. Detection and treatment of outliers) http://docs.cntd.ru/document/1200146680
2. *Osborne J. W.* The power of outliers (and why researchers should always check for them). – https://scholarworks.umass.edu/pare/vol9/iss1/6/
3. Глоссарий: статистическая помощь. - http://www.statHelp.ru/glossary_stat.html
4. Электронный учебник. – http://www.statsoft.ru/home/textbook/glossary/gloss_v.html
5. *High R.* Dealing with 'Outliers': How to Maintain Your Data's Integrity. – http://cc.uoregon.edu/cnews/spring2000/outliers.html
6. Fallon, Ch. Spada: Detection and Accommodation of Outliers in Normally Distributed Data Sets. – https://www.cee.vt.edu/ewr/environmental/teach/smprimer/outlier/outlier.html
7. МЕДФАР – АНАЛИСТ: http://www.rusmedserv.com/medstat/article002.htm
8. Описание процедуры и результатов статистического анализа медицинских данных в научных публикациях. - http://www.mediasphera.ru/recom/rebrova.htm

9. *Кобзарь А.И.* Прикладная математическая статистика. Для инженеров и научных работников. - М.: ФИЗМАТЛИТ, 2006. – 816 с.
10. *Дэйвид Г.* Порядковые статистики. Пер. с англ. / Под ред. В.В. Петрова. – М.: Наука, 1979. – 336 с.
11. Frank E. Grubbs. Sample Criteria for Testing Outlying observations. – http://links.jstor.org
12. *Дубров А.М., Мхитарян В.С., Трошин Л.И.* Многомерные статистические методы: Учебник. – М.: ЮНИТИ-ДАНА, 2001. – 656 с.
13. *Мостеллер Ф., Тьюки Дж.* Анализ данных и регрессия. В 2-х вып: Вып. 2. / Пер. с англ. / Под ред. Ю.П. Адлера. – М.: Финансы и статистика, 1982. – 239 с.
14. *Aggarwal C.C., Yu P.S.* Outlier Detection for High Dimensional Data. – http://portal.acm.org/citation.cfm?id=375668
15. *Knorr E.M.* Algorithms for Mining Distance-Based Outliers in Large Datasets. – http://www.vldb.org/conf/1998/p392.pdf
16. *Knorr E.M., Raymond T. Ng., Tucakov V.* Distance-Based outliers: algorithms and applications. – http://citeseer.ist.psu.edu/cachedpage/294396
17. *Li W.Q., Lying Zh., Wen J., Jeffrey X. Yu.* HOT: Hypergraph-based Outlier Test for Categorical Data. – http://citeseerx.ist.psu.edu/viewdoc/summary?doi=10.1.1.10.7164
18. *Уикем Х., Гроулмунд Г.* Язык R в задачах науки о данных импорт, подготовка, обработка, визуализация и моделирование данных. – СПб.: ООО «Диалектика», 2018. – 592 с.
19. *Кабаков Р.И.* R в действии. Анализ и визуализация данных на языке R. – М.: ДМК Пресс, 2014. – 588 с.
20. *Мастицкий С. Э.* Статистический анализ и визуализация данных с помощью R. [Электронный ресурс] / С. Э. Мастицкий, В. К. Шитиков – 2014. – 401 с.
21. *Josse J., Mayer I., Tierney N., Vialaneix N.* CRAN Task View: Missing Data. – https://cloud.r-project.org/web/views/MissingData.html