Министерство науки и высшего образования РФ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Ижевский государственный технический университет
имени М.Т. Калашникова»
(ИжГТУ имени М.Т. Калашникова)
Факультет «Математика и естественные науки»
Кафедра «Прикладная математика и информационные технологии»

Практическая работа № 2
по курсу **«Информационные технологии анализа и обработки данных»**
Вариант 7

Направление подготовки 01.03.02 «Прикладная математика»
Профиль – «Прикладной анализ данных и искусственный интеллект»

Проверил: В. Г. Суфиянов
доктор технических наук, профессор

Выполнил: М. А. Панин
студент группы Б23-183-1

Ижевск - 2026

СОДЕРЖАНИЕ

Введение 3
Задание 1. Операции с таблицами из методических указаний 3
Создание, отбор и объединение строк 3
Преобразование таблицы рейсов 4
Задание 2. Обработка встроенных данных 4
Задание 3. Обработка внешних данных 6
Задание 4. Сравнение времени выполнения 7
Заключение 8

Введение

Цель практической работы — освоить создание, загрузку и обработку таблиц стандартными средствами R и функциями пакета `dplyr`. Сначала выполнены операции из методических указаний. Затем для варианта 7 обработаны квартальный ряд численности населения Австралии `austres` и ответы Stack Overflow Developer Survey за 2022 год. Время выполнения сравнивается на одной и той же операции группировки.

Расчёты выполнены в R 4.6.2.

Задание 1. Операции с таблицами из методических указаний

Создание, отбор и объединение строк

В примерах 2.1–2.6 построена таблица из четырёх строк. В `data.frame` столбцы могут иметь разные типы, при этом их длины совпадают. В учебном примере столбцы `x`, `y`, `z` имеют целочисленный, строковый и логический типы соответственно. При отборе по условию `x > 2` остаются строки с ключами 3 и 4. При объединении по ключу `x` сохраняются только значения 1, 2 и 3, присутствующие в обеих таблицах.

Листинг 1.1 — Создание таблицы и отбор строк

```
df <- data.frame(x = 1:4, y = LETTERS[1:4], z = c(TRUE, FALSE))
df[3:4, -1, drop = FALSE]
subset(df, x > 2, select = c(x, y))
df_key <- data.frame(x = c(3, 2, 6, 1),
                     s = c(100, 1000, 300, 500))
merge(df, df_key, by = "x")
```

Операция `rbind()` добавляет наблюдения с теми же полями, `cbind()` объединяет столбцы по позиции строки, а `merge()` сопоставляет строки по значению ключа. В примере 2.7 таблица `mtcars` из 32 наблюдений и 11 переменных дополнена сведениями о шкалах. Форма двигателя и тип коробки передач переведены в факторы, а количество цилиндров, передач и карбюраторов — в упорядоченные факторы.

Листинг 1.2 — Шкалы признаков в таблице автомобилей

```
cars_with_scales <- within(datasets::mtcars, {
  vs <- factor(vs, levels = c(0, 1), labels = c("V", "S"))
  am <- factor(am, levels = c(0, 1),
               labels = c("automatic", "manual"))
  cyl <- ordered(cyl)
  gear <- ordered(gear)
  carb <- ordered(carb)
})
```

Преобразование таблицы рейсов

На таблице `nycflights13::flights` (336 776 строк, 19 столбцов) проверены отбор, сортировка, выбор и переименование полей, удаление повторов, вычисление признаков, агрегирование и случайная выборка. Разность задержек при прилёте и вылете выражена в минутах, её отношение ко времени полёта — в минутах за час.

Листинг 1.3 — Выбор рейсов по дате и выделение маршрутов

```
january_1 <- filter(flights, month == 1, day == 1)
january_february <- filter(flights, month %in% c(1, 2))
routes <- distinct(select(flights, origin, dest))
nrow(january_1)
nrow(january_february)
```

Листинг 1.4 — Расчёт разности задержек за время полёта

```
mutate(flights,
  gain = arr_delay - dep_delay,
  gain_per_hour = gain / (air_time / 60)
)
summarise(flights, delay = mean(dep_delay, na.rm = TRUE))
```

В `mutate()` поле `gain_per_hour` использует только что вычисленное `gain`. При аналогичном вызове `transform()` обращение к `gain` завершается ошибкой, поскольку такого столбца в исходной таблице ещё нет. На 1 января приходится 842 рейса, на январь и февраль вместе — 51 955. Без пропусков средняя задержка вылета составляет около 12,6 мин. Выборка в 1 % содержит 3 368 строк.

Задание 2. Обработка встроенных данных

Ряд `austres` содержит 89 наблюдений со II квартала 1971 года по II квартал 1993 года.

Таблица 2.1 — Поля квартальной таблицы

Поле	Смысл и тип	Единица
Год	Целочисленный год	Год
Квартал	Порядковый номер от 1 до 4	Квартал
Население	Вещественная численность	Тыс. человек
Прирост	Вещественная разность соседних значений	Тыс. человек

Листинг 2.1 — Квартальные приращения и отбор полных лет

```
population_ts <- datasets::austres
pop <- as.numeric(population_ts)
population <- data.frame(
  year = as.integer(time(population_ts)),
  quarter = as.integer(cycle(population_ts)),
  population_thousands = pop,
  quarter_change_thousands = c(NA_real_, diff(pop))
)
quarters_by_year <- table(population$year)
full_years <- names(quarters_by_year[quarters_by_year == 4L])
complete_years <- subset(population, year %in% full_years)
december <- subset(complete_years, quarter == 4L)
```

Численность за весь период выросла с 13 067,3 до 17 661,5 тыс. человек. По 21 полному году вычислены приращение $N_4 - N_3$ и средний уровень $\frac{N_1+N_2+N_3+N_4}{4}$, где N_i — численность в квартале i. Результаты объединены по календарному году.

Листинг 2.2 — Группировка и соединение по году

```
yearly_average <- aggregate(
  population_thousands ~ year, data = complete_years, FUN = mean
)
yearly <- merge(
  december[c("year", "population_thousands",
             "quarter_change_thousands")],
  yearly_average, by = "year"
)
```

Таблица 2.2 — Примеры годовых сводок в тысячах человек

Год	Уровень в IV квартале	Изменение за IV квартал	Средний уровень
1972	13 409,3	55,4	13 330,27
1992	17 568,7	42,7	17 506,15

Задание 3. Обработка внешних данных

Выбрана одна волна опроса, чтобы использовать единый набор полей и одинаковые определения признаков. CSV за 2022 год в сборке Kaggle повреждён, поэтому использован CSV из официального выпуска Stack Overflow. Проверены наличие четырёх выбранных полей и уникальность идентификаторов всех 73 268 анкет. Пустые значения представлены как `NA`.

Таблица 3.1 — Признаки опроса, использованные в обработке

Признак	Смысл	Тип и единица
Идентификатор	Уникальный номер анкеты	Целое, безразмерный ключ
Страна	Страна по ответу участника	Строка, категория
Стаж	Стаж работы по ответу участника	Числовой, годы
Языки	Языки, указанные за последний год	Строка, список категорий

С помощью `select()` оставлены нужные поля, `rename()` присваивает рабочие имена, а `mutate()` добавляет число языков в анкете. Список языков разделён по разделителю из CSV. Пустой ответ остаётся пропуском. Страна отсутствует в 1 497 анкетах, стаж — в 36 499. Средний стаж по заполненным ответам составляет 10,24 года.

Листинг 3.1 — Переименование признаков и подсчёт языков

```
survey_fields <- survey |>
  select(ResponseId, Country, WorkExp,
         LanguageHaveWorkedWith) |>
  rename(country = Country, work_years = WorkExp) |>
  mutate(language_count = if_else(
    is.na(LanguageHaveWorkedWith),
    NA_integer_,
    lengths(strsplit(LanguageHaveWorkedWith, ";", fixed = TRUE))
  ))
```

Листинг 3.2 — Сводка по странам для стажа от пяти лет

```
survey_fields |>
  filter(!is.na(country), work_years >= 5) |>
  group_by(country) |>
  summarise(
    responses = n(),
    mean_work_years = mean(work_years),
    .groups = "drop"
  ) |>
  arrange(desc(responses), country)
```

Таблица 3.2 — Страны с наибольшим числом анкет после отбора

Страна	Число анкет	Средний стаж, лет
США	5 877	16,45
Германия	1 961	12,79
Индия	1 882	9,26

Задание 4. Сравнение времени выполнения

В обеих реализациях отбираются анкеты с известной страной и стажем от пяти лет. Средние по странам вычисляются через `aggregate()` или `group_by()` и `summarise()`. После согласования порядка строк результаты для 162 стран совпали с учётом числовой точности.

Листинг 4.1 — Средний стаж в двух реализациях группировки

```
summarise_base <- function(data) {
  selected <- subset(data, !is.na(Country) & WorkExp >= 5)
  aggregate(WorkExp ~ Country, data = selected, FUN = mean)
}
summarise_dplyr <- function(data) data |>
  filter(!is.na(Country), WorkExp >= 5) |>
  group_by(Country) |>
  summarise(WorkExp = mean(WorkExp), .groups = "drop")
```

Листинг 4.2 — Проверка совпадения средних по странам

```
base_result <- summarise_base(survey)
dplyr_result <- summarise_dplyr(survey)
row_order <- match(base_result$Country, dplyr_result$Country)
dplyr_aligned <- dplyr_result[row_order, ]
stopifnot(
  nrow(base_result) == nrow(dplyr_result),
  identical(base_result$Country, dplyr_aligned$Country),
  isTRUE(all.equal(base_result$WorkExp, dplyr_aligned$WorkExp))
)
```

Листинг 4.3 — Оценка времени одного вызова

```
measure_ms <- function(method, data) {
  replicate(5L, {
    elapsed <- system.time(
      for (i in seq_len(20L)) invisible(method(data))
    )[["elapsed"]]
    elapsed * 1000 / 20L
  })
}
```

Каждая серия включает 20 вызовов. Если длительность серии t выражена в секундах, время вызова в миллисекундах равно $1000 \cdot \frac{t}{20}$. Чтение CSV и вывод результатов не входят в замер.

Таблица 4.1 — Время вызова по пяти сериям, мс

Реализация	Медиана	Минимум	Максимум
base R	61,5	49,5	73,5
`dplyr`	28,5	22,5	32,0

Отношение медиан составляет $\frac{61{,}5}{28{,}5} \approx 2{,}16$. Это результат конкретной группировки на одном наборе данных и в одной среде запуска.

Заключение

Команды создания, выбора и объединения таблиц проверены на учебных данных. По квартальному ряду получена сводка по 21 полному году, а по анкетам — распределение числа ответов и среднего стажа по странам. Обе реализации группировки дали совпадающие результаты. В выполненном замере медиана времени составила 28,5 мс для `dplyr` и 61,5 мс для base R.