ПРАКТИЧЕСКАЯ РАБОТА № 3.

Анализ данных и визуализация средствами языка программирования R

Цель работы – получить навыки анализа и визуализации данных в среде программирования R.

Задачи:

1. Изучить возможности анализа и визуализации данных на языке программирования R с использованием стандартных библиотек.
2. Выполнить задания, представленные в данной работе.
3. Выполнить дополнительные задания.
4. Оформить отчет в формате *.doc, *.docx или *.pdf и выгрузить в системе электронного обучения ee.istu.ru в курсе «Информационные технологии анализа и обработки данных».

Порядок выполнения работы

Лабораторная работа основана на учебном пособии: *Самсонов Т.Е.* Визуализация и анализ географических данных на языке R. М.: Географический факультет МГУ, 2019. DOI: 10.5281/zenodo.901911, которое свободно распространяются на сайте https://github.com/tsamsonov/r-geo-course/tree/master. Загрузите файлы, представленные на сайте, и откройте файл .

Данный модуль посвящен введению в работу с графическим представлением информации в R. Построение графиков на языке R сродни работе с конструктором: вы собираете изображение по кирпичикам из множества настроек и компонент. Поняв основные принципы базовой графической подсистемы **R** из пакета **graphics**, вы сможете освоить дополнительные библиотеки **lattice**, **ggplot2** и **plotly**, предоставляющие еще более интересные возможности с точки зрения функциональности и дизайна.

Прежде чем мы приступим к построению графиков, необходимо подготовить исходные данные. Мы будем работать с региональной статистикой Росстата: экспорт/импорт продукции по регионам России (млн долл. США) и объем сброса сточных вод по морям России (млрд. $м^3$):

```
library(readxl)

# Прочтем таблицу по экспорту/импорту продукции в регионах России
types = c("text", rep("numeric", 12))
tab = as.data.frame(read_excel("data/ExpImp.xlsx", 1, col_types = types))
str(tab)
## 'data.frame':    96 obs. of  13 variables:
##  $ Регион     : chr  "Российская Федерация" "Центральный федеральный округ"
"Белгородская область" "Брянская область" ...
##  $ ПродЭкспорт: num  16196.2 4552.9 221.9 28.5 177.9 ...
##  $ ПродИмпорт : num  43076 22954 614 650 454 ...
##  $ ТЭКЭкспорт : num  371791.8 204331.7 64.7 5 0.9 ...
##  $ ТЭКИмпорт  : num  3613.6 1660.3 24.1 20.5 16.7 ...
##  $ ХимЭкспорт : num  30739.2 8442.7 33.3 24.5 87.7 ...
```

```
##  $ ХимИмпорт  : num  50129.5 34870.4 242.8 71.7 419 ...
##  $ ДревЭкспорт: num  10965.8 1101.6 6.2 23.4 57.1 ...
##  $ ДревИмпорт : num  6641.5 3942.6 43.3 44.9 9 ...
##  $ МетЭкспорт : num  40859.3 9877 2014.1 50.5 29 ...
##  $ МетИмпорт  : num  22017.4 11763.6 1207.3 68.3 56.6 ...
##  $ МашЭкспорт : num  28338.5 12845.9 84.1 143.2 286.1 ...
##  $ МашИмпорт  : num  154371 96196 1710 823 469 ...
```

```
# Выгрузим данные по федеральным округам в отдельную таблицу
filter = grep("федеральный округ", tab$Регион)
okr = tab[filter, ]
# Отсортируем данные по федеральным округам в алфавитном порядке:
okr = okr[order(okr$Регион), ]
# Выгрузим данные по субъектам в отдельную таблицу
filter = grepl("федеральный округ|Федерация|числе",tab$Регион)
sub = tab[!filter, ]
```

Графики (точечные и линейные) – базовый и наиболее часто используемый способ визуализации. Универсальная функция `plot()` позволяет строить графики по координатам, которые передаются, соответственно, в первый и второй аргумент. Если переменные и не связаны друг с другом явным образом, то такой график называется *диаграммой рассеяния*.

Диаграммы рассеяния

Диаграмма рассеяния позволяет установить, есть ли зависимость между переменными, а также понять, как объекты различаются по значениям переменных.

```
par(mar=c(4,4,3,2))
# Диаграмма рассеяния по экспорту и импорту:
plot(sub$МетЭкспорт,
     sub$МетИмпорт,
     col="red",
     xlab="Экспорт, млн. долл. США",
     ylab = "Импорт, млн. долл. США",
     main = "Экспорт/импорт металлов и изделий из них по субъектам РФ",
     asp = 1)
```

На рисунке 3.1 представлены результаты построения диаграммы.

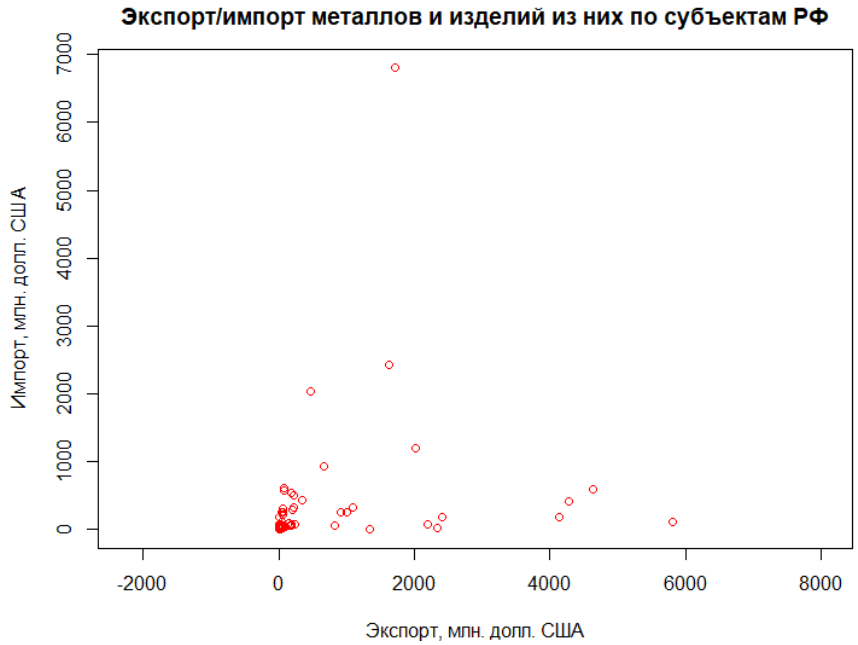


Рисунок 3.1 – Экспорт/импорт металлов и изделий из них по субъектам РФ

При построении диаграмм рассеяния важно сохранить одинаковый масштаб по осям. Чтобы обеспечить это условие, необходимо использовать параметр `asp = 1`.

В данном случае четко выделяется группа субъектов вблизи начала координат, не отличающихся интенсивным экспортом и импортом продукции металлургии, а также очевидно преобладание экспорта над импортом при больших объемах товарооборота.

Попробуйте изменить размер окна на вкладке *Plots*. Вы увидите, что масштаб по осям сохраняется пропорциональным.

Размер и тип значка можно изменить, используя параметры `pch=` и `cex=`.

Размеры масштабируются параметром `cex` относительно условной единицы — стандартного размер значка. Сам значок можно выбрать, используя его код в соответствии с рисунком 3.2.



Рисунок 3.2 – Типы точек

```
plot(sub$МетЭкспорт,
     sub$МетИмпорт,
     col="red",
     xlab="Экспорт, млн. долл. США",
     ylab = "Импорт, млн. долл. США",
     main = "Экспорт/импорт металлов и изделий из них по субъектам РФ",
     asp = 1,
     pch = 20,
     cex = 1.5)
```

На рисунке 3.3 представлены результаты построения диаграммы.



Рисунок 3.3 – Экспорт/импорт металлов и изделий из них по субъектам РФ

Линейные графики отражают связь между зависимой и независимой переменной. Существует два способа нанесения линий на график: явное рисование линий *поверх уже построенного графика* с помощью функции `lines()`, или создание нового линейного графика с помощью функции `plot()` с дополнительным параметром `type =`.

Для иллюстрации принципов работы первого способа откроем еще раз данные по объему сброса загрязненных сточных вод по морям России (млрд куб. м).

```
tab = read.csv2("data/oxr_vod.csv", encoding = 'UTF-8')
plot(tab$Год, tab$Каспийское, pch=20) # для начала нанесем точки
lines(tab$Год, tab$Каспийское) # теперь нанесем линии
```

На рисунке 3.4 представлены результаты построения диаграммы.

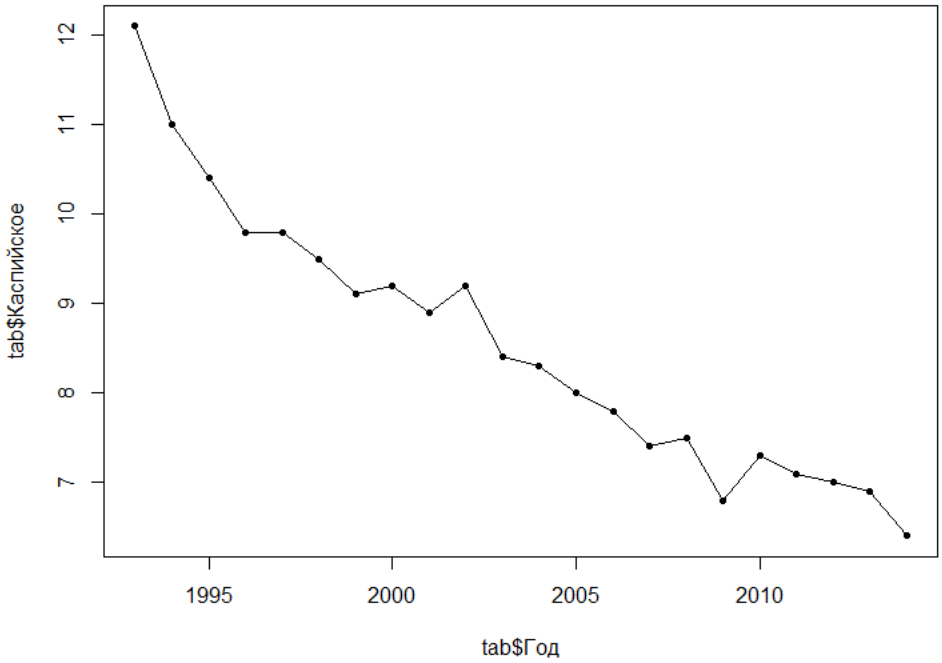


Рисунок 3.4 – Объем сброса загрязненных сточных вод в Каспийское море

По умолчанию функция `plot()` рисует именно точки. Однако если точки не нужны, а достаточно только линий, или требуется иной подход к построению графиков, можно задать параметр `type =`, который принимает следующие значения:

- `"p"` for points,
- `"l"` for lines,
- `"b"` for both,
- `"c"` for the lines part alone of “b”,
- `"o"` for both ‘overplotted’,
- `"h"` for ‘histogram’ like (or ‘high-density’) vertical lines,
- `"s"` for stair steps,
- `"S"` for other steps, see ‘Details’ below,
- `"n"` for no plotting.

Рассмотрите разные методы визуализации.

```
plot(tab$Год, tab$Карское,pch=20)
plot(tab$Год, tab$Каспийское, type="p")
plot(tab$Год, tab$Каспийское, type="l")
plot(tab$Год, tab$Каспийское, type="b")
plot(tab$Год, tab$Каспийское, type="c")
plot(tab$Год, tab$Каспийское, type="o")
plot(tab$Год, tab$Каспийское, type="h")
plot(tab$Год, tab$Каспийское, type="s")
```

Толщину и тип линии можно изменить, используя параметры lwd = и lty = соответственно. Работают они аналогично параметрам pch и cex для точечных символов. Типов линий по умолчанию в стандартной библиотеке R не так много, но в сочетании с цветовым кодированием и толщиной их оказывается вполне достаточно (рисунок 3.5).



Рисунок 3.5 – Типы линий

Рассмотрите разные варианты представления линий.

```
plot(tab$Год, tab$Каспийское, type="l", lwd = 2, lty = 1)
plot(tab$Год, tab$Каспийское, type="l", lwd = 3, lty = 2)
plot(tab$Год, tab$Каспийское, type="l", lwd = 1, lty = 3)
```

Часто бывает необходимо совместить на одном графике несколько рядов данных. Для этого можно поступить двумя путями:

1. Нарисовать один ряд данных с помощью функции `plot()`, а затем добавить к нему другие ряды с помощью функций `points()` и `lines()`.
2. Нарисовать пустой график, а затем добавить к нему все ряды данных с помощью функций `points()` и `lines()`.

При совмещении нескольких рядов данных на одном графике в первом же вызове функции `plot()` необходимо заложить диапазон значений по осям охватывающий все ряды данных. В противном случае будет учтен только разброс значений первого ряда данных, и остальные ряды могут не поместиться в поле графика.

Вариант реализации 1 способа представлен на рисунке 3.6.

```
plot(tab$Год,
     tab$Каспийское,
     xlab="Год",
     ylab = "Объем сброса, млрд.куб.м.",
     pch=20,
     type="o",
     ylim = c(0,12),
     col="red3")
# Добавим теперь на существующий график новый ряд данных, используя функции
points() и lines():
points(tab$Год, tab$Карское, pch=20, col="forestgreen")
lines(tab$Год, tab$Карское, pch=20, col="forestgreen")
```

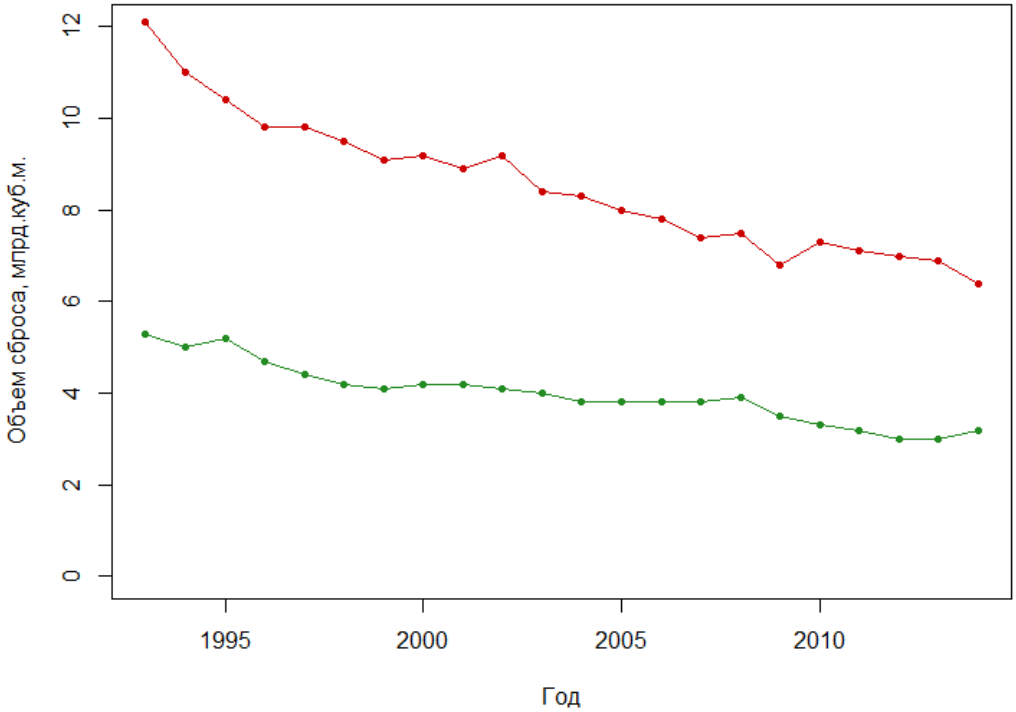


Рисунок 3.6 – Объем сброса загрязненных сточных вод в Каспийское и Карское море

Теперь рассмотрим второй вариант. Заодно устраним недостаток предыдущего кода, в котором диапазон значений по осям указывался вручную.

```
xrange = range(tab$Год) # вычислим диапазон по оси X
yrange = range(tab$Каспийское, tab$Карское, tab$Азовское) # вычислим диапазон по
оси Y

# Построим пустой график, охватывающий полный диапазон данных, и имеющий все
необходимые сопроводительные элементы
plot(xrange,
     yrange,
     main="Объем сброса загрязненных сточных вод",
     xlab="Год",
     ylab="млрд.куб.м",
     type = "n") # n означает, что ряд данных рисоваться не будет

# Теперь добавим на график ряды данных
points(tab$Год, tab$Каспийское, pch=20, col="red3")
lines(tab$Год, tab$Каспийское, pch=20, col="red3")

points(tab$Год, tab$Карское, pch=20, col="forestgreen")
lines(tab$Год, tab$Карское, pch=20, col="forestgreen")

points(tab$Год, tab$Азовское, pch=20, col="steelblue")
lines(tab$Год, tab$Азовское, pch=20, col="steelblue")
```

Вариант реализации 2 способа представлен на рисунке 3.7.

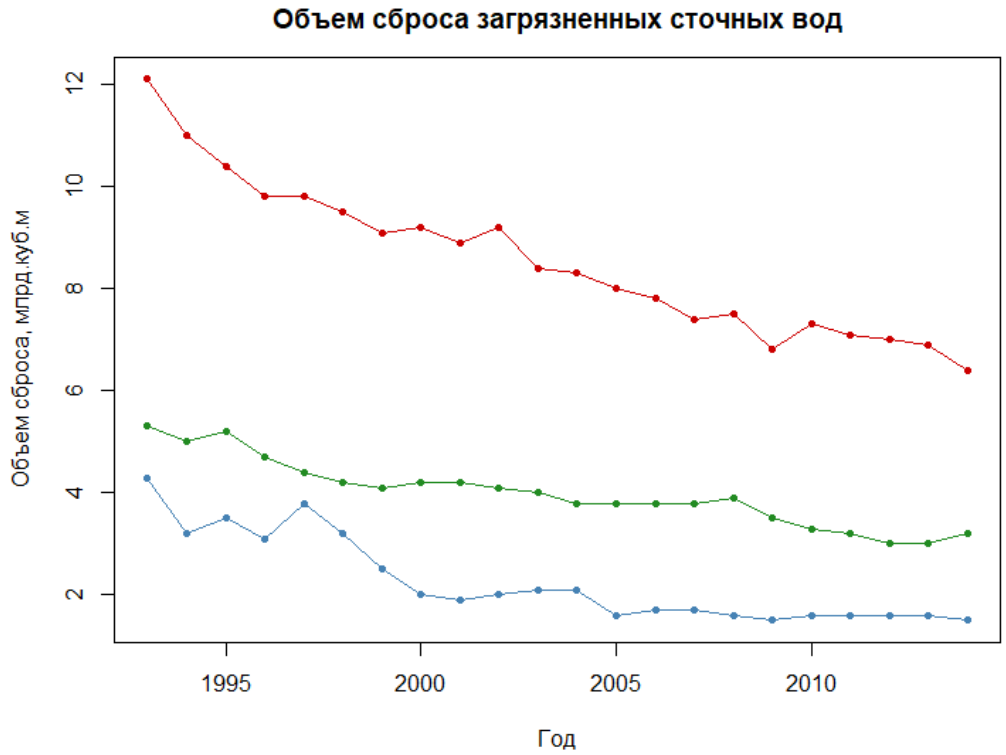


Рисунок 3.7 – Объем сброса загрязненных сточных вод в Каспийское и Карское море

Функциональные параметры

Графические параметры при построении графиков на самом деле могут быть не константами, а *функцией* данных. Например, вы можете сказать, что размер точки при построении диаграммы рассеяния должен быть функцией отношения экспорта к импорту, что усилит наглядность отображения:

```
plot(okr$МетЭкспорт,
     okr$МетИмпорт,
     col=rgb(1,0,0,0.5),
     xlab="Экспорт, млн. долл. США",
     ylab = "Импорт, млн. долл. США",
     main = "Экспорт/импорт металлов и изделий из них по ФО РФ (2013 г.)",
     asp = 1,
     pch = 20,
     cex = 2+log(sub$МетИмпорт/sub$МетЭкспорт)) # размер кружка зависит от
соотношения импорта и экспорта
```

На рисунке 3.8 представлены результаты построения диаграммы.

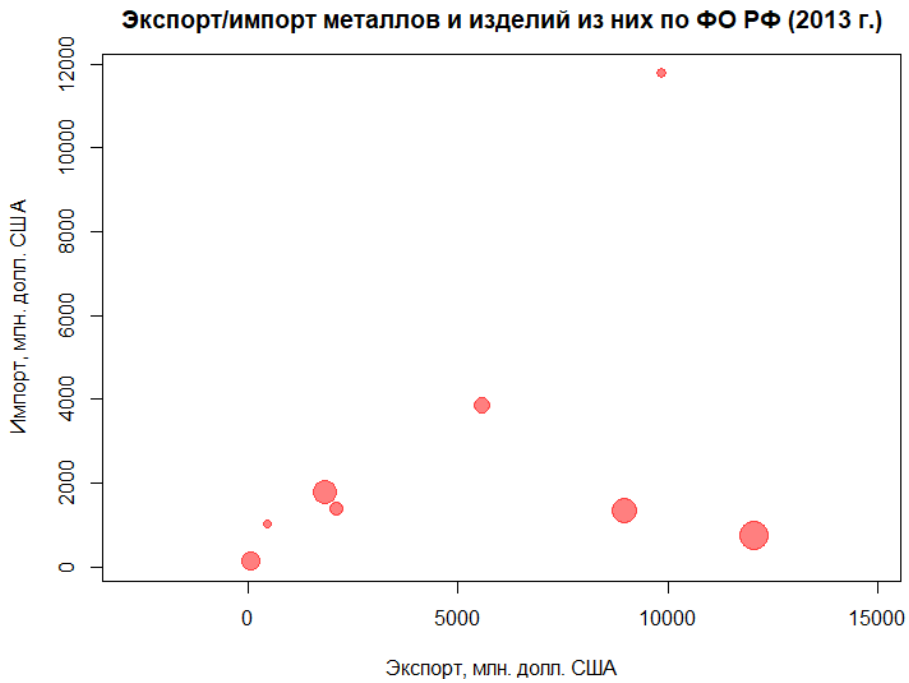


Рисунок 3.8 – Экспорт/импорт металлов и изделий из них по федеральным округам РФ

Гистограммы

Гистограммы распределения строятся с помощью функции `hist()`. Чтобы изменить ширину кармана (столбца) гистограммы, необходимо задать параметр `breaks =`, а цвет задается в параметре `col`.

```
# Карманы будут от 0 до 3000 через 100. Заодно добавим цвет:
hist(sub$ПродЭкспорт, breaks = seq(0,3000,100), col="olivedrab3")
```

На рисунке 3.9 представлены результаты построения диаграммы.

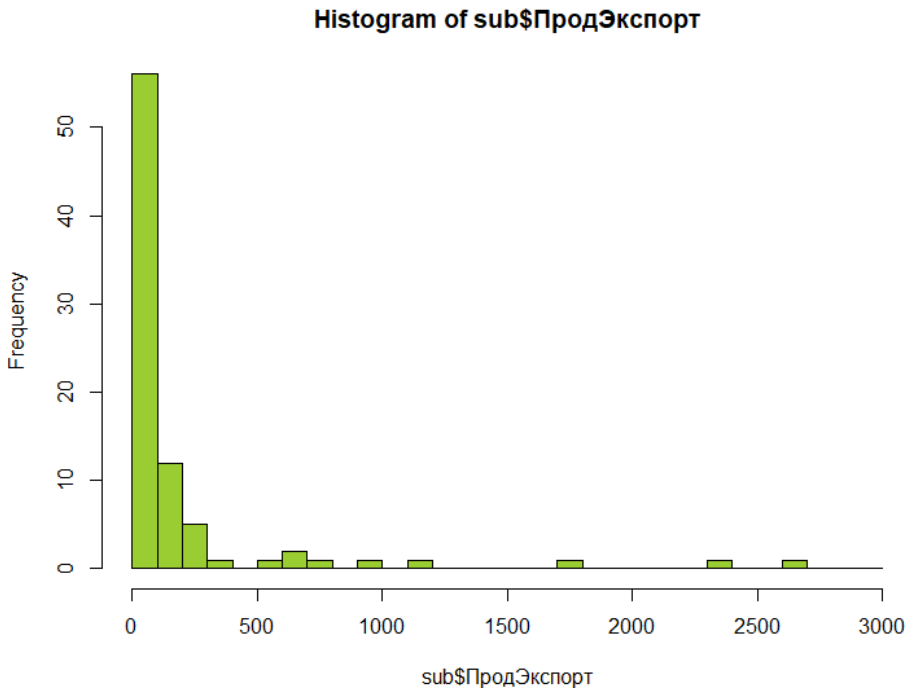


Рисунок 3.9 – Распределение экспорта металлов и изделий из них по регионам РФ

Столбчатые графики

Столбчатые графики — **barplot** — отображают вектор числовых данных в виде столбиков. Это простейший вид графика (наряду с *dotchart*), который используется для сравнения абсолютных величин. Для построения необходимо вызвать функцию `barplot()` и передать ей столбец таблицы:

```
par(mar=c(17,4,1,2))
# Если у каждого столбика есть название,
# нужно передать вектор названий в аргумент names.arg =
barplot(okr$ХимЭкспорт, names.arg = okr$Регион, las = 3)
```

На рисунке 3.10 представлены результаты построения диаграммы.

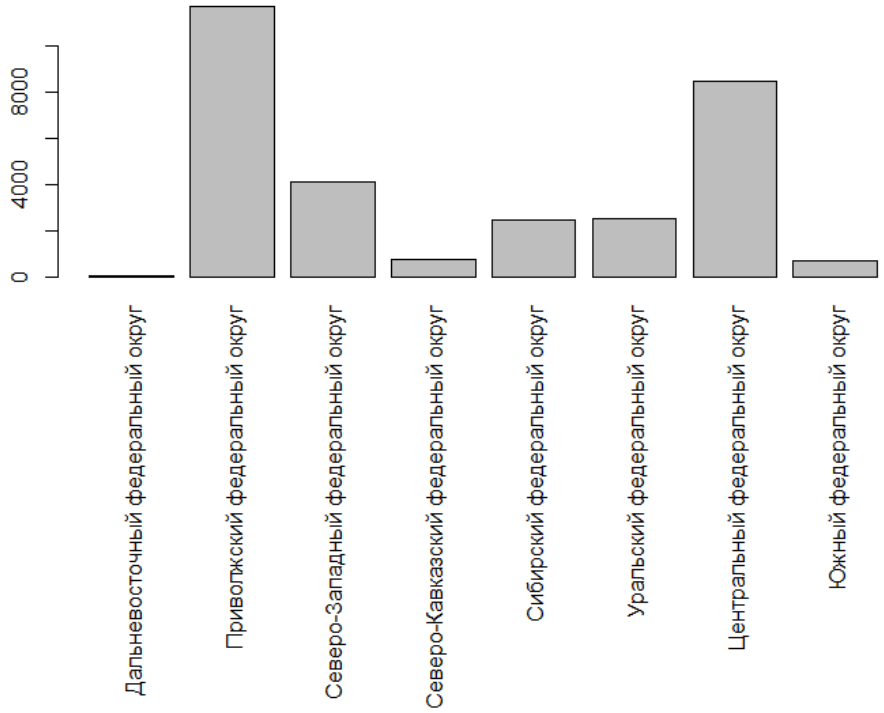


Рисунок 3.10 – Экспорт/импорт изделий химической промышленности по федеральным округам РФ

Чтобы развернуть подписи перпендикулярно столбцам, следует использовать параметр `las =`. Справка R говорит нам о том, что этот параметр дает следующее поведение подписей:

- 0: всегда параллельно осям (по умолчанию),
- 1: всегда горизонтально,
- 2: всегда перпендикулярно осям,
- 3: всегда вертикально.

Выберем вариант, при котором столбцы представлены горизонтально.

```
par(mar=c(3,17,1,2))
barplot(okr$ХимЭкспорт, names.arg = okr$Регион, horiz=TRUE, las = 1)
```

На рисунке 3.11 представлены результаты построения диаграммы.

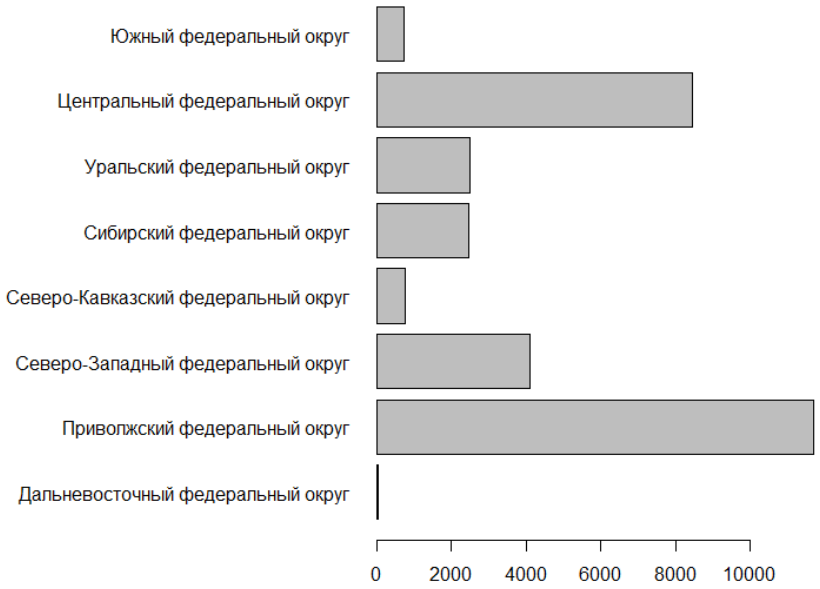


Рисунок 3.11 – Экспорт/импорт изделий химической промышленности по федеральным округам РФ

В данном случае очень массивные названия федеральных не умещаются в пространство графика. Можно было бы вполне убрать словосочетание “федеральный округ”. Для этого используем `sub()`.

```
names = sub("федеральный округ", "", okr$Регион) # "" - означает пустая строка
par(mar=c(3,9,1,2))
barplot(okr$ХимЭкспорт, names.arg = names, horiz = TRUE, las = 1)
```

На рисунке 3.12 представлены результаты построения диаграммы.

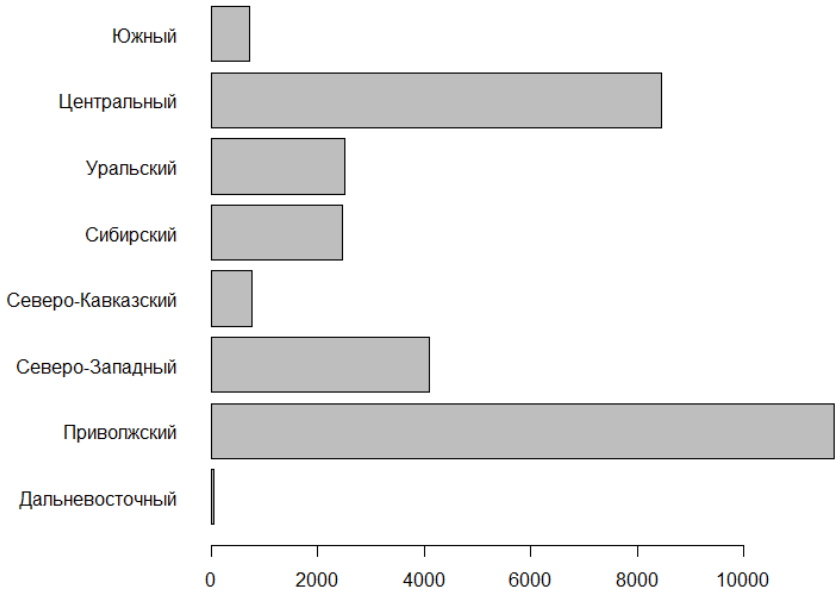


Рисунок 3.12 – Экспорт/импорт изделий химической промышленности по федеральным округам РФ

Далее необходимо выполнить примеры построения диаграмм из 5 главы [1]:
5.4 Круговые (секторные) диаграммы
5.5 Цвет и прозрачность
5.6 Настройки отображения
5.7 Легенда

Порядок выполнения работы

Задания необходимо выполнить встроенными средствами языка программирования R и функциями, реализованными в библиотект dplyr.

Информация о таблицах данных (data.frame) и библиотеке dplyr содержится в документации введение в язык программирования R https://cran.r-project.org/doc/manuals/r-release/R-intro.html#Data-frames.

Список заданий для самостоятельного выполнения

В таблице 3.1 представлены варианты наборов данных для самостоятельной работы. Задание на работу:

1. Выполните команды представленные в теоретической части работы.

2. Загрузить данные указанные в табл. 3.1 в R.

3. Приведите примеры визуализации данные из datasets в соответствии со своим вариантом (табл. 3.1).

4. Приведите примеры выполнения операций над внешними данными в соответствии со своим вариантом (табл. 3.1).

Примерные варианты индивидуальных заданий

Таблица 3.1. Варианты наборов данных для обработки

№	Данные из datasets	Внешние данные
1.	airmiles	Latest Global Temperatures (https://www.kaggle.com/datasets/csafrit2/latest-global-temperatures)
2.	AirPassengers	Finance companies in India (https://www.kaggle.com/datasets/anuragbantu/finance-companies-in-india)
3.	airquality	Black Friday Sales EDA(https://www.kaggle.com/datasets/pranavuikey/black-friday-sales-eda)
4.	anscombe	Football Transfers from 1992/93 to 2021/22 seasons(https://www.kaggle.com/datasets/cbhavik/football-transfers-from-199293-to-202122-seasons)

5.	attenu	World, Region, Country GDP/GDP per capita (https://www.kaggle.com/datasets/tmishinev/world-country-gdp-19602021)
6.	attitude	Air Pollution Level (https://www.kaggle.com/datasets/totoro29/air-pollution-level)
7.	austres	Stack Overflow Developer Survey 2011-2022 (https://www.kaggle.com/datasets/yasirabdaali/stack-overflow-developer-survey-20112022)
8.	beaver1	Financing Healthcare (https://www.kaggle.com/datasets/programmerrdai/financing-healthcare)
9.	beaver2	Law School Admissions Bar Passage (https://www.kaggle.com/datasets/danofer/law-school-admissions-bar-passage)
10.	beavers	Vending Machine Sales (https://www.kaggle.com/datasets/awesomeasingh/vending-machine-sales)
11.	BJsales	Global Companies dataset (https://www.kaggle.com/datasets/narayan63/global-companies-dataset)
12.	BJsales.lead	Smoke Detection Dataset (https://www.kaggle.com/datasets/deepcontractor/smoke-detection-dataset)
13	BOD	Netflix Data: Cleaning, Analysis and Visualization (https://www.kaggle.com/datasets/ariyoomotade/netflix-data-cleaning-analysis-and-visualization)
14.	cars	World Population by Countries Dataset (1960-2021) (https://www.kaggle.com/datasets/kaggleashwin/population-dataset)
15.	ChickWeight	Online Retails Sale Dataset (https://www.kaggle.com/datasets/rohitmahulkar/online-retails-sale-dataset)
16.	chickwts	Spotify unpopular songs (https://www.kaggle.com/datasets/estienneggx/spotify-unpopular-songs)
17.	CO2	Chocolate Bar Ratings (https://www.kaggle.com/datasets/evangower/chocolate-bar-ratings)
18.	co2	Airbnb Open Data (https://www.kaggle.com/datasets/arianazmoudeh/airbnbopendata)
19	crimtab	IMDB Movies (https://www.kaggle.com/datasets/totoro29/imdb-movies)
20.	DNase	Youtube Statistics (https://www.kaggle.com/datasets/advaypatil/youtube-statistics)

Список литературы

1. *Самсонов Т.Е.* Визуализация и анализ географических данных на языке R. М.: Географический факультет МГУ, 2019. DOI: 10.5281/zenodo.901911, которое свободно распространяются на сайте https://github.com/tsamsonov/r-geo-course/tree/master.
2. *Кабаков Р.И.* R в действии. Анализ и визуализация данных в программе R / пер. с.англ. Полины А. Волковой. – М.: ДМК Пресс, 2014. – 588 с.
3. *Уикем Х., Гроулмунд Г.* Язык R в задачах науки о данных импорт, подготовка, обработка, визуализация и моделирование данных. – СПб.: Диалектика, 2018. – 592 с.
4. *Митина О.А.* Языки программирования для статистической обработки данных [Электронный ресурс]: Учебное пособие / Митина О.А., Юрченков И.А. — М.: МИРЭА – Российский технологический университет, 2020. — 191 с.
5. *Шишкин В.А.* Математические пакеты: R [Электронный ресурс] : учебное пособие / В. А. Шишкин ; Пермский государственный национальный исследовательский университет. – Электронные данные. – Пермь, 2023. – 15,0 Мб ; 225с. – Режим доступа: http://www.psu.ru/files/ docs/science/books/uchebnie-posobiya/SHishkin-Matematicheskie-pakety-R.pdf
6. *Зарядов И.С.* Введение в статистический пакет R: типы переменных, структуры данных, чтение и запись информации, графика: Учебно-методическое пособие М.: Издательство Российского университета дружбы народов, 2010. – 207 с.

Список вопросов

1. Какая функция базового пакета R отвечает за построение стандартных графиков (диаграмм рассеяния, линейных)?
2. Какие функции стандартной библиотеки R позволяют построить: столбчатые диаграммы, круговые секторные диаграммы, гистограммы?
3. Как задать интервал или количество интервалов гистограммы?
4. Можно ли разместить столбчатую диаграмму горизонтально? Если да, то как?
5. Какая функция отвечает за установку параметров графической подсистемы?
6. Как установить поля вокруг графиков?
7. Как развернуть подписи на столбчатой диаграмме перпендикулярно оси?
8. Как установить запрет на экспоненциальное представление больших чисел при рисовании графиков?
9. Какой параметр отвечает за установку цвета в функциях построения графиков стандартной библиотеки R?
10. Какие параметры отвечают за установку толщины и типа линии на графиках?
11. Какие параметры отвечают за установку размера и типа значка на диаграммах рассеяния?
12. Как совместить несколько графиков на одной сетке координат?
13. Какая функция рисует рамку вокруг графика?
14. Какая функция отвечает за рисование сетки координат?
15. Как установить равный масштаб по осям графика?
16. Какие параметры позволяют масштабировать текст элементов графика, таких как подписи координат, осей, заголовков и подзаголовков?
17. Назовите способы задания цвета в R.
18. Как сделать цвет в R полупрозрачным?
19. Назовите стандартные цветовые палитры R.
20. Как сгенерировать последовательность из нужного количества цветов между заданными опорными цветами?
21. Какая функция позволяет разместить легенду на графике?
22. Как сделать так, чтобы в легенде показывались точки? Линии?