Министерство науки и высшего образования РФ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Ижевский государственный технический университет
имени М.Т. Калашникова»
(ИжГТУ имени М.Т. Калашникова)
Факультет «Математика и естественные науки»
Кафедра «Прикладная математика и информационные технологии»

Практическая работа № 4
по курсу **«Информационные технологии анализа и обработки данных»**
Вариант 7

Направление подготовки 01.03.02 «Прикладная математика»
Профиль – «Прикладной анализ данных и искусственный интеллект»

Проверил: В. Г. Суфиянов
доктор технических наук, профессор

Выполнил: М. А. Панин
студент группы Б23-183-1

Ижевск - 2026

СОДЕРЖАНИЕ

Введение 3
Задание 1. Загрузка и описание данных 3
Источники и подготовка 3
Схема проверяемых полей 4
Задание 2. Поиск аномалий 5
Проверка стажа и обязательных значений 6
Результаты проверок 6
Интерпретация счётчиков 7
Задание 3. Расчёт показателей качества 7
Заключение 8

Введение

Цель работы — оценить пригодность двух наборов для анализа по критериям качества данных. Для варианта 7 из таблицы 4.3 методических указаний к ПР № 4 (2024, с. 53–67) исследованы квартальные оценки численности населения Австралии из `datasets::austres` и анкеты Stack Overflow Developer Survey за 2022 год.

В R проверены структура записей, форматы, целостность, согласованность и покрытие. Счётчики рассчитаны по отдельным правилам. Одна запись может попасть в несколько счётчиков.

Задание 1. Загрузка и описание данных

Источники и подготовка

Единица наблюдения в `austres` — квартальная оценка численности. Ключ объединяет год и номер квартала. Эталоном покрытия служит шкала самого ряда, содержащая 89 кварталов со II квартала 1971 года по II квартал 1993 года. Период в текстовой справке R отличается от индексов объекта.

Единица наблюдения в опросе — опубликованная анкета. В CSV волны 2022 из назначенного архива Kaggle после записи 68 809 обнаружен двоичный фрагмент. Расчёты проведены на оригинальном публичном релизе Stack Overflow за 2022 год, содержащем 73 268 анкет и 79 полей. Имена и содержание вопросов сверены со словарём этого релиза.

Поля опроса прочитаны как текст. Функция `count.fields` учитывает запятые и переносы внутри кавычек. Пустые строки и маркер `NA` обработаны как пропуски. Домен проверен после обрезки крайних пробелов, а нерегулярность — по исходной записи.

Листинг 1.1 — Построение квартальных ключей

```
population <- data.frame(
  Quarter = sprintf("%d-Q%d",
                    floor(time(datasets::austres) + 1e-8),
                    cycle(datasets::austres)),
  Population = as.numeric(datasets::austres)
)
```

Схема проверяемых полей

Таблица 1.1 — Атрибуты квартального ряда

Поле	**Содержание**	**Тип, формат и единицы**
`Quarter`	Отчётный квартал	Временной ключ, `YYYY-Qn`
`Population`	Численность населения Австралии	Десятичное число, тыс. человек

Таблица 1.2 — Ключевые атрибуты опроса

Поле	**Содержание**	**Тип, формат и единицы**
`ResponseId`	Идентификатор анкеты	Положительное целое
`MainBranch`	Роль респондента	Номинальная категория
`Country`	Страна проживания	Номинальная категория
`Age`	Возрастная группа	Порядковая категория
`RemoteWork`	Формат работы	Номинальная категория: офисный, гибридный или удалённый
`YearsCode` и `YearsCodePro`	Общий и профессиональный стаж программирования	Число лет или граничная категория
`WorkExp`	Опыт работы	Целое число лет
`Currency`	Валюта оплаты	Три заглавные буквы, пробел или табуляция, название
`CompTotal` и `CompFreq`	Сумма и период выплаты	Десятичное число в исходной валюте, категория периода
`ConvertedCompYearly`	Пересчитанная оплата	Десятичное число, USD за год

Среди 79 атрибутов также есть поля об образовании, технологиях, инструментах, рабочих процессах и использовании Stack Overflow. Множественный выбор представлен строкой с ответами, разделёнными точкой с запятой.

Задание 2. Поиск аномалий

Таблица 2.1 — Правила выявления аномалий

Аномалия	Условие срабатывания
Лексическая ошибка	Ширина CSV-записи отличается от ширины заголовка.
Ошибка формата домена	Непустое значение нарушает формат или отсутствует в перечне допустимых категорий.
Нерегулярность	Крайние пробелы либо более редкий разделитель между кодом валюты и её названием.
Нарушение целостности	Нет ключа, обязательного поля или входов для годовой оплаты. Опыт или сумма отрицательны.
Противоречие	Строки с одним ключом различаются или числовой профессиональный стаж превышает общий.
Дубликат	Повтор ключа после первого вхождения либо повтор всей строки при пропуске ключа.
Недопустимый кортеж	Корректно записанный ключ находится за границей проверяемого реестра.
Отсутствующее значение	Ячейка пуста, хотя правило требует её заполнения.
Отсутствующий кортеж	Эталонный ключ отсутствует в наборе.

У `austres` проверяется положительность численности. В анкете обязательны ключ и роль. При наличии годовой оплаты ожидаются сумма, валюта и период. Строка с ошибками нескольких доменов учитывается один раз.

Листинг 2.1 — Объединение флагов домена и проверка покрытия

```
outside_format <- function(values, pattern) {
  !is.na(values) & !grepl(pattern, values, perl = TRUE)
}
expected_ids <- as.character(seq_len(73268L))
bad_domain <- Reduce(`|`, domain_errors)
absent_ids <- setdiff(expected_ids, key)
sum(bad_domain)
length(absent_ids)
```

Проверка стажа и обязательных значений

При сравнении двух видов стажа граничные текстовые категории исключаются из числового сравнения. В счётчик попадают анкеты с двумя числовыми ответами, где профессиональный стаж больше общего.

Листинг 2.2 — Поиск противоречий в стаже

```
exp_total <- suppressWarnings(as.numeric(clean$YearsCode))
exp_pro <- suppressWarnings(as.numeric(clean$YearsCodePro))
bad_experience <- !is.na(exp_total) & !is.na(exp_pro) &
  exp_pro > exp_total
sum(bad_experience)
```

Поля суммы, валюты и периода проверяются при известной годовой оплате.

Листинг 2.3 — Подсчёт условно обязательных пропусков

```
known_pay <- !is.na(clean$ConvertedCompYearly)
pay_inputs <- c("Currency", "CompTotal", "CompFreq")
missing_pay_inputs <- sum(vapply(clean[pay_inputs], function(x) {
  sum(known_pay & is.na(x))
}, 0L))
```

Результаты проверок

Таблица 2.2 — Число выявленных аномалий

Аномалия	austres	Опрос 2022	Единица
Лексические ошибки	0	0	строк
Ошибки формата домена	0	1	строк
Нерегулярность	0	14 983	строк
Нарушения целостности	0	0	строк
Противоречия	0	499	строк
Дубликаты	0	0	строк
Недопустимые кортежи	0	0	строк
Отсутствующие значения	0	0	ячеек
Отсутствующие кортежи	0	0	ключей

Интерпретация счётчиков

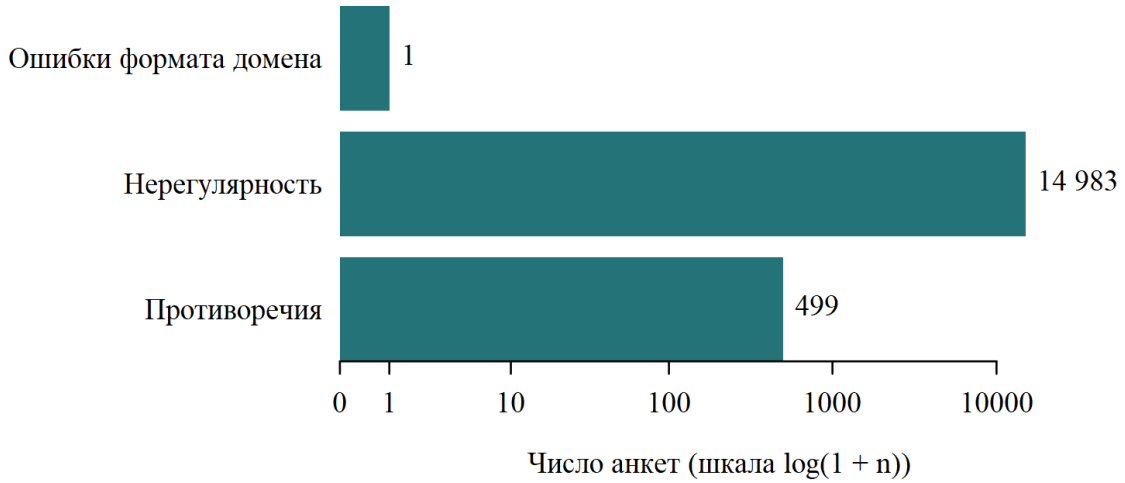


Рисунок 2.1 — Ненулевые счётчики аномалий в опросе 2022 года

Шкала $\log(1+n)$ позволяет показать редкие и частые нарушения на одном рисунке. Указаны исходные счётчики. Ошибка домена найдена в `Currency`. Нерегулярность отмечена в 12 803 ячейках `Currency`, в 2 114 ячейках `WebframeHaveWorkedWith` и в 1 419 ячейках `WebframeWantToWorkWith`. После объединения флагов получено 14 983 анкеты. В 499 анкетах числовой профессиональный стаж превышает общий.

Задание 3. Расчёт показателей качества

Обозначим через N число записей, через K число ожидаемых ключей, через u число отсутствующих ключей, через P число столбцов и через p число столбцов с нерегулярными значениями. Тогда полнота $1 - \frac{u}{K}$, однородность $1 - \frac{p}{P}$. Если m обязательных или условно ожидаемых ячеек пусты при общем числе M таких ячеек, плотность пропусков равна $\frac{m}{M}$.

Для остальных показателей используется отношение числа строк, удовлетворяющих правилу, к N. Достоверность учитывает ограничения целостности и допустимость ключа. Соответствие схеме основано на ширине записи и проверенных форматах домена. Согласованность требует также отсутствия нерегулярности и противоречия. Уникальность равна доле строк после исключения повторов ключей.

Листинг 3.1 — Расчёт долей по флагам проверок

```
checks <- survey_checks
bad_schema <- checks$lexical | checks$domain
bad_consistency <- bad_schema | checks$contradiction |
  Reduce(`|`, checks$irregular)
c(validity = mean(!(checks$integrity | checks$invalid)),
  schema = mean(!bad_schema),
  consistency = mean(!bad_consistency),
  uniqueness = mean(!checks$duplicate))
```

Таблица 3.1 — Показатели качества в процентах

Показатель	austres	Опрос 2022
Полнота	100,0000	100,0000
Достоверность	100,0000	100,0000
Согласованность	100,0000	79,0004
Соответствие схеме	100,0000	99,9986
Однородность	100,0000	96,2025
Плотность пропусков	0,0000	0,0000
Уникальность	100,0000	100,0000

Листинг 3.2 — Доля пустых ячеек по всем полям опроса

```
blank_by_field <- vapply(survey, function(x) {
  sum(is.na(x) | trimws(x) == "")
}, 0L)
100 * sum(blank_by_field) / prod(dim(survey))
```

Нулевая плотность пропусков относится к проверенному перечню ожидаемых ячеек. По всем 79 полям пусты 28,43 % ячеек, включая необязательные ответы и вопросы, которые могли не показываться респонденту. Полнота 100 % оценивает покрытие опубликованного реестра, а оценка представительности опроса потребовала бы данных о генеральной совокупности.

Заключение

Квартальный ряд полностью покрывает проверяемую шкалу. В опросе представлены все ключи опубликованной волны. Основной вклад в снижение согласованности до 79,00 % внесли различия в записи категорий. При группировке данных по валюте следует извлекать единый код. При анализе стажа целесообразно отдельно проверить чувствительность результатов к отмеченным 499 анкетам.