# ПРАКТИЧЕСКАЯ РАБОТА № 4.

## Технологии и методы оценки качества данных

Цель работы – научится оценивать качество данных с использованием средств R

Задачи:

1. Изучить теоретические основы оценки качества данных.
2. Изучить методы оценки качества данных на языке программирования R.
3. Выполнить задания для самостоятельного выполнения, представленные в данной работе.
4. Оформить отчет в формате *.doc, *.docx или *.pdf и выгрузить в системе электронного обучения ee.istu.ru в курсе «Информационные технологии анализа и обработки данных».

### Качество данных

Качество данных — обобщенное понятие, характеризующее степень пригодности информации для анализа (ГОСТ Р ИСО 8000-2-2019). Существует целый ряд критериев, которые используются для оценки правильности, полноты, точности и надежности данных.

Оценка данных как «качественные» или «некачественные», а также ее разные градации (плохая, хорошая, отличная) — имеют субъективный характер и должны рассматриваться непосредственно в контексте решаемой задачи.

Существует ряд критериев, которые применяются для оценки правильности, полноты, точности и надежности данных. Наиболее используемые из них перечислены ниже [1].

### Критерии качества данных

Условно критерии можно разбить на 3 группы. Первая – это требования к содержанию данных, вторая – вопрос согласованности информации, а третья – удобство работы.

Наиболее критичны проблемы первой группы. Их игнорирование может привести к полной невозможности анализировать. Отсутствие согласованности снижает доверие к принимаемым решениям, а неудобство использования повышает затраты.

**Содержание данных**

**Правильность** (accuracy) – это соответствие данных реальности и корректность их интерпретации. Например, корректность данных о количестве выпускаемой продукции зависит от того, как они были получены, учтены и внесены в системы учета. Очевидно, что неправильные данные нельзя использовать для принятия решений.

**Полнота** (completeness) – достаточность объема, глубины и широты наборов данных. Неполнота приводит либо к невозможности анализа, либо к необходимости отталкиваться от некоторых предположений или допущений относительно пропущенной информации. Полнота может касаться как пропусков в атрибутах анализируемых объектов, например, не заполненные сведения в справочнике товаров, так и отсутствия части исследуемых данных, например, сведений за определенный период.

**Релевантность** (relevance) – показатель того, насколько данные соответствуют целям и решаемым задачам. Например, сведения о продажах бумажных книг могут быть нерелевантными для рынка электронных, либо данные о предпочтениях клиентов в одной стране могут полностью отличаться от пользователей в другой.

**Объективность** (objectivity) – уверенность, что данные не содержат предвзятых мнений или субъективных оценок. Особенно много проблем с объективностью возникает, когда анализируются данные опросов или обратной связи от клиентов. Сказывается человеческий фактор: оценка качества одной и той же услуги/товара одним пользователем может кардинально отличаться от мнения другого.

**Достоверность** (validity) – соответствие многочисленным атрибутам, связанных с элементом данных: тип, точность, формат, диапазоны допустимых значений и так далее. Например, в поле e-mail строка должна соответствовать стандарту написания электронных адресов.

**Точность** (precision) – детальность измерения и фиксации данных. В зависимости от особенностей процесса и целей анализа показатели необходимо фиксировать с точностью до дня, часа, минуты или секунды, либо вес товара измерять с точностью до тонны или грамма.

**Своевременность** (timeliness) – время после сбора данных, по прошествии которого они становятся доступными для анализа. Оно должно соответствовать скорости анализируемого процесса. Корректные, но устаревшие данные бесполезны для принятия оперативных решений.

**Согласованность**

**Уникальность** (uniqueness) подразумевает, что ни один объект не существует в наборе данных более одного раза. Наличие дублей может приводить к несогласованности и противоречиям вследствие отсутствия единой версии правды.

**Целостность** (integrity) – наличие корректных ссылок между данными и их соответствие установленным правилам и ограничениям. Ссылочная целостность предполагает, что все ссылки из данных в одном столбце таблицы на данные в другом столбце той же или другой таблицы являются допустимыми, т.е. не будет ситуации, при которой запись в таблице продаж ссылается на покупателя, отсутствующего в справочнике клиентов.

**Согласованность** (consistency) – соответствие данных друг другу и их логическая непротиворечивость. Например, соответствие пола человека его имени, а даты рождения – возрасту. Если данные не согласованы, это может указывать на ошибки или неточности в их сборе или обработке.

**Когерентность** (coherence) – согласованность с другими источниками данных и логикой процесса, который они описывают. Например, данные о

затратах на производство не должны противоречить данным о количестве продукции, произведенной в тот же период.

**Надежность** (reliability) – возможность повторного получения одинаковых результатов. Если результаты измерения получатся разные в зависимости от условий, то снижается доверие к принятым на их основе решениям.

**Удобство**

**Доступность** (accessibility) показывает, насколько легко пользователю узнать, какие данные имеются в его распоряжении, а также получить доступ к ним. Причем речь может идти в том числе и о метаданных, описывающих анализируемую информацию. Например, данные, которые доступны только в печатном виде сложно оперативно использовать для анализа.

**Удобство использования** (usability) характеризует, насколько легко и просто использовать данные для изучения определенной проблемы. Например, информация может быть в наличии, в том числе и в электронном виде, но ее **применение** для анализа может требовать сложной предобработки. Это особенно характерно для неструктурированных данных: изображения, аудио, видео.

**Универсальность** (universality) определяет, насколько данные могут использоваться для разных целей и задач. Например, информация о продажах универсальная, т.к. может пригодиться для исследования различных вопросов: финансы, логистика, маркетинг, планирование производства.

**Контролируемость** (traceability) или прослеживаемость – возможность осуществления контроля качества и происхождения данных посредством отражения их источников, истории создания, изменения, преобразования, удаления, хранения и передачи.

**Переносимость** (portability) – возможность переноса данных между разными платформами или службами без потери их целостности или иных препятствий. Сложности интеграции, импорта или экспорта данных существенно снижают их ценность.

### Обеспечение качества

Обеспечение качества данных включает в себя этапы наблюдения, анализа и совершенствования информации. Для управления качеством данных существует множество методов и подходов:

1. Очистка – удаление некорректных, неполных, дублирующихся и неактуальных записей.
2. Стандартизация – приведение данных к единому формату и стандарту, что помогает улучшить согласованность, точность и полноту данных.
3. Валидация – проверка данных на соответствие определенным правилам и требованиям, таким как форматы, допустимые значения, наличие или отсутствие специальных символов и т.д.
4. Установка метрик – определение показателей, которые будут использоваться для оценки качества данных, таких как точность, полнота, актуальность, согласованность и т.д.
5. Мониторинг данных – отслеживание на постоянной основе, позволяющее выявлять проблемы в данных и решать их в режиме реального времени.

### Аномалии данных

Одной из причин причина ухудшения качества данных – это наличие аномалий. Аномалии данных делятся на синтаксические, семантические и аномалии охвата [2].

Синтаксические аномалии описывают характеристики, касающиеся формата и значений, используемых для представления сущностей.

Семантические аномалии мешают сбору данных быть исчерпывающим и неизбыточным представлением предметной области.

Аномалии покрытия уменьшают количество сущностей и свойств сущностей из предметной области, которые представлены в сборе данных.

### Синтаксические аномалии

**Лексическими ошибками** называются несоответствия между структурой элементов данных и заданным форматом. Например, предположим, что данные хранятся в виде таблицы, где каждая строка представляет кортеж, а каждый столбец – атрибут (таблица 4.1). Если предполагается, что таблица будет иметь четыре столбца, потому что каждый кортеж имеет четыре атрибута, но некоторые или все строки содержат только три столбца, то фактическая структура данных не соответствует указанному формату. Лексически правильные данные могут быть представлены в указанной структуре токена.

*Таблица 4.1.* Таблица данных с лексическими ошибками

| Name | Age | Gender | Size |
|---|---|---|---|
| Петя | 23 | M | 7’1 |
| Вася | 34 | M | |
| Сюзанна | 21 | 5’8 | |

**Ошибки формата домена** определяют ошибки, когда заданное значение атрибута не соответствует ожидаемому формату домена. Учитывая конкретное значение «Джон Смит», хотя это, возможно, правильное имя, оно не удовлетворяет заданному формату значений домена из-за отсутствия запятой между словами.

Лексические ошибки классов аномалий и ошибки формата домена часто подпадают под термин **синтаксическая ошибка**, поскольку они представляют собой нарушения общего формата.

**Нерегулярность** связана с неравномерным использованием значений, единиц измерения и сокращений. Это может произойти, например, если для определения заработной платы сотрудников используются разные валюты. Это особенно важно, если валюта не указана явно для каждого значения и предполагается, что она единообразна. Это приводит к тому, что ценности являются правильным представлением фактов, если у нас есть необходимые знания об их представлении, необходимые для их интерпретации. Другой пример – использование или разное использование сокращений. Непоследовательное использование значений затрудняет сопоставимость

кортежей, что влияет на кластеризацию, устранение дубликатов или других задач анализа.

**Семантические аномалии**

**Нарушения ограничения целостности** описывают кортежи (или наборы кортежей), которые не удовлетворяют одному или нескольким ограничениям целостности. Ограничения целостности используются для описания нашего понимания предметной области путем ограничения набора допустимых экземпляров. Каждое ограничение – это правило, представляющее знания о предметной области и значениях, разрешенных для представления определенных фактов, например, ВОЗРАСТ > 0.

**Противоречия –** это значения внутри одного кортежа или между кортежами, которые нарушают какую-то зависимость между значениями. Примером для первого случая может быть противоречие между атрибутом AGE и DATE_OF_BIRTH для кортежа, представляющего людей. Противоречия – это либо нарушения функциональных зависимостей, которые могут быть представлены как ограничения целостности, либо дубликаты с неточными значениями. Поэтому они не рассматриваются как отдельные аномалии данных во всем напоминании об этом документе.

**Дубликаты** – это два или более кортежа, представляющих одну и ту же сущность из предметной области. Значения этих кортежей не обязательно должны быть полностью идентичными. Неточные дубликаты – это частные случаи противоречия между двумя или более кортежами. Они представляют одну и ту же сущность, но с разными значениями всех или некоторых ее свойств. Это усложняет обнаружение дубликатов и их слияние.

**Недопустимые кортежи** представляют собой наиболее сложный класс аномалий, обнаруживаемых в коллекциях данных. Под недопустимыми подразумеваются кортежи, которые не отображают аномалии классов, определенных выше, но все же не представляют действительные сущности из предметной области. Они возникают из-за нашей неспособности описать

реальность в рамках формальной модели с помощью ограничений целостности. Их чрезвычайно трудно найти и еще сложнее исправить, потому что нет правил (или ограничений), которые нарушаются этими кортежами, а с другой стороны, у нас есть только неполные знания о каждой сущность в предметной области.

### Аномалии покрытия

**Отсутствующие значения** являются результатом пропусков при сборе данных. Это в некоторой степени нарушение ограничения, если есть нулевые значения для атрибутов, для которых существует ограничение NOT NULL. В других случаях может не быть такого ограничения, что позволяет использовать нулевые значения для атрибута. В этих случаях необходимо решить, существует ли значение в предметной области и должно быть выведено здесь или нет. Как аномалии рассматриваются только те пропущенные значения, которые должны существовать в коллекции данных, поскольку объект имеет соответствующее свойство с измеряемым значением, но не содержится в данных.

**Отсутствующие кортежи** являются результатом пропусков полных сущностей, существующих в предметной области, которые не представлены кортежами в сборе данных.

Аномалии могут быть дополнительно классифицированы в соответствии с объемом данных, учитывающих нарушение ограничения. Это могут быть отдельные значения, значения в кортеже, значения в одном или нескольких столбцах коллекции данных или кортежи и наборы кортежей из разных отношений.

### Очистка данных и качество данных

Наличие аномалий в реальных данных мотивирует разработку и применение методов очистки данных. С помощью приведенных выше определений теперь можно определить очистку данных и указать, как измерить результат очистки ошибочных данных.

Чтобы данные можно было обрабатывать и интерпретировать эффективным и действенным образом, они должны удовлетворять набору критериев качества. Данные, удовлетворяющие этим критериям качества, считаются высококачественными.

Чтобы измерить качество сбора данных, необходимо оценить баллы по каждому критерию качества, представленному на рисунке 4.1. Оценка баллов для критериев качества может использоваться для количественной оценки необходимости очистки данных для сбора данных, а также успешности выполненного процесса очистки данных при сборе данных. Критерии качества также могут использоваться при оптимизации очистки данных путем указания приоритетов для каждого из критериев, который, в свою очередь, влияет на выполнение методов очистки данных, влияющих на конкретные критерии.

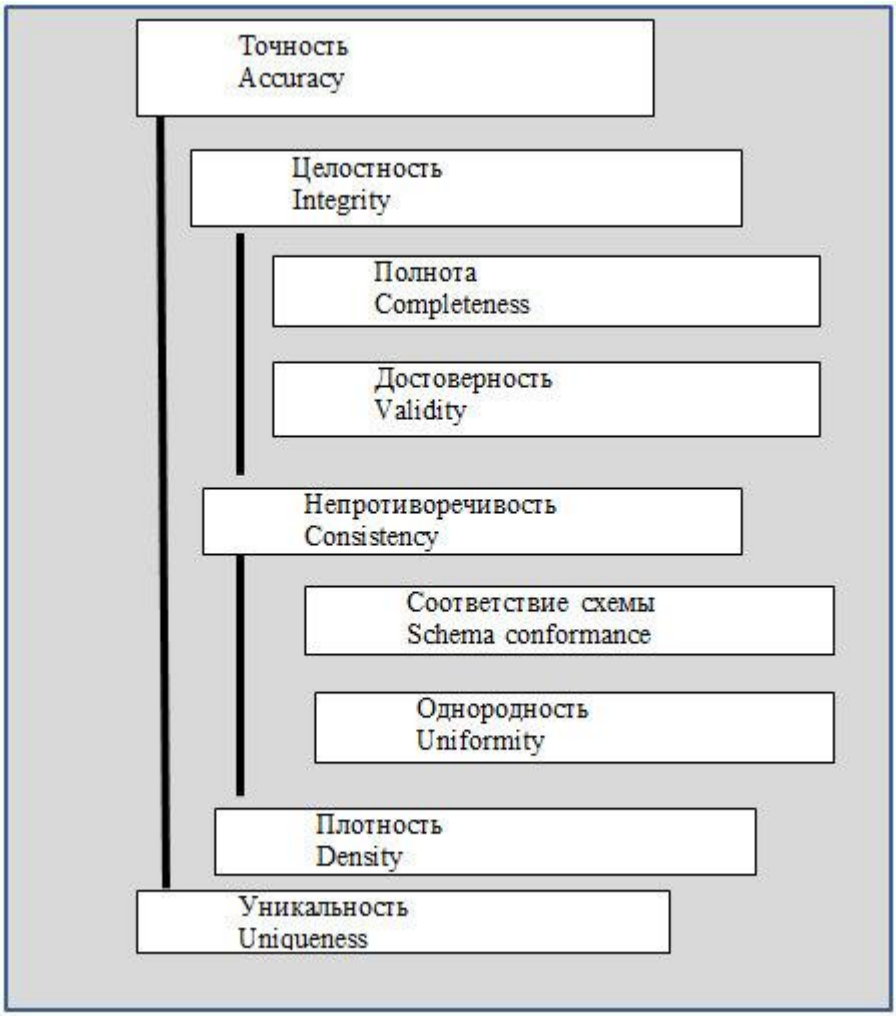



Рисунок 4.1 – Иерархия критериев качества данных

Критерии качества, определенные для комплексной очистки данных, образуют иерархию. Эта иерархия является результатом разделения критериев качества на более мелкие критерии качества. Для каждого из критериев описывается, как оценить показатель качества для данной коллекции данных. На оценку каждого критерия качества влияет одна или несколько аномалий. В таблице 4.2 представлены критерии качества и аномалии, влияющие на них.

**Точность** или правильность (accuracy) определяется как отношение количества правильных значений в наборе данных к общему количеству значений.

Точность описывается как агрегированное значение по критериям качества «Целостность», «Последовательность» и «Плотность». Интуитивно это описывает точное, единообразное и полное представление предметной области, то есть сбор данных, не содержащий каких-либо определенных аномалий, кроме Дубликатов.

Целостность подразделяется на критерии полноты и достоверности и, следовательно, представляет собой агрегированное значение. Интуитивно понятно, что целостный набор данных содержит представления всех сущностей в предметной области и только тех, то есть нет недопустимых кортежей или нарушений ограничений целостности, а также отсутствующих кортежей.

**Полнота** (completeness) определяется как отношение сущностей, представленных кортежами, к общему количеству сущностей. Достижение этой формы полноты является не основной задачей очистки данных, а скорее проблемой интеграции данных. Полнота в очистке данных достигается путем исправления кортежей, содержащих аномалии, а не только путем удаления этих кортежей, если они являются представлениями сущностей.

**Достоверность** (validity) – это отношение сущностей, представленных кортежами, к общему количеству кортежей, т.е. процент кортежей, представляющих (действительные) сущности. Идентификация недействительных кортежей сложна, а иногда и невозможны из-за невозможности или высокой стоимости повторных измерений для проверки

правильности измеренного значения. Достоверность может быть приблизительно определена с использованием ограничений целостности. Ограничения целостности отражают наше понимание закономерностей предметной области. Поэтому кортежи, нарушающие ограничения целостности, считаются недопустимыми. Нарушения ограничений возникают в системах, которые не обеспечивают полное соблюдение ограничений целостности. Это может быть из-за системных ограничений или по требованию пользователя, возможно, из-за проблем с производительностью. Достоверность оценивается как отношение кортежей, удовлетворяющих всем ограничениям целостности, к общему количеству кортежей.

**Непротиворечивость** или согласованность (consistency) касается как синтаксических аномалий, так и противоречий. Далее он подразделяется на соответствие схемы и единообразие, формируя другое агрегированное значение по критериям качества. Интуитивно последовательный сбор данных синтаксически единообразен и свободен от противоречий.

**Соответствие схеме** (schema conformance) – это отношение кортежей, соответствующих синтаксической структуре, к общему количеству кортежей. Некоторые системы не обеспечивают полную синтаксическую структуру, что позволяет использовать кортежи в коллекции, которые не полностью соответствуют формату. Это касается систем реляционных баз данных, где соблюдение форматов доменов является обязанностью пользователя.

**Однородность** (uniformity) связана с неоднородностями, то есть с правильным использованием значений в каждом атрибуте. Семантика и использование значений должны быть единообразными. Однородность – это отношение атрибутов, не содержащих отклонений в их значениях, к общему количеству атрибутов.

**Плотность** (density) – это отношение отсутствующих значений в кортежах к общему количеству значений, которые должны быть известны. По-прежнему могут существовать несуществующие значения или свойства, которые должны

быть представлены нулевыми значениями, имеющими точное значение «неизвестность».

**Уникальность** (uniqueness) – это отношение кортежей, представляющих одну и ту же сущность в предметной области, к общему количеству кортежей. Уникальная коллекция не содержит дубликатов. Ссылаясь на определение точности как на коллекцию, не содержащую никаких аномалий, кроме дубликатов, сбор данных, являющийся точным и уникальным, не содержит никаких аномалий.

В таблице 4.2 перечислены определенные критерии качества и аномалии, влияющие на них. Включены только те критерии, которые не делятся на подкритерии. Знак ● указывает на прямое понижение критериев качества, а знак «–» указывает, что возникновение этой аномалии затрудняет обнаружение других аномалий, понижающих критерии качества.

*Таблица 4.2.* Аномалии данных, влияющие на критерии качества данных

| | Полнота | Достовер-ность | Соответ-ствие схеме | Одно-родность | Плот-ность | Уникаль-ность |
|---|---|---|---|---|---|---|
| Лексические ошибки | | – | ● | – | – | – |
| Ошибки формата домена | | – | ● | – | | – |
| Нерегулярность | | – | | ● | | – |
| Нарушения ограничения целостности | | ● | | | | |
| Отсутствующие значения | | | | | ● | – |
| Отсутствующие кортежи | ● | | | | | |
| Дубликаты | | | | | | ● |
| Недопустимые кортежи | | ● | | | | |

**Комплексная очистка данных**

Комплексная очистка данных определяется как совокупность операций, выполняемых с существующими данными для удаления аномалий и получения сбора данных, являющегося точным и уникальным представлением предметной области. Это (полу) автоматический процесс операций, выполняемых с данными,

которые выполняют, предпочтительно в этом порядке, (i) адаптацию формата для кортежей и значений, (ii) обеспечение соблюдения ограничений целостности, (iii) вывод отсутствующих значений из существующих, (iv) устранение противоречий внутри или между кортежами, (v) слияние и удаление дубликатов и (vi) обнаружение выбросов, т. е. кортежей и значений, имеющих высокий потенциал недействительности. Очистка данных может включать в себя структурное преобразование, то есть преобразование данных в формат, который лучше поддается управлению или лучше подходит для предметной области. Однако качество схемы не является прямым вопросом очистки данных и, следовательно, не входит в список критериев качества, определенных выше.

**Список заданий для самостоятельного выполнения**

В таблице 4.1 представлены варианты наборов данных для самостоятельной работы. Задание на работу:

1. Изучить главу 15 «Продвинутые методы работы с пропущенными данными» [3, стр. 472-498] для выявления пропущенных значений и главу 9 «Аккуратизация данных с помощью пакета tidyr» [4, стр. 207-231] для обработки таблиц данных с использованием библиотеки tidyr.
2. В соответствии со своим вариантом загрузить данные указанные в таблице 4.3.
3. Представить описание атрибутов данных (название, физическое описание, тип переменной, единицы измерения).
4. Определите форматы представления атрибутов. Сформулируйте и реализуйте на языке программирования R функции для проверки наличия аномалий в данных.
5. Реализуйте на языке программирования R функции для определения наличия и вычисления количества: лексических ошибок, ошибок формата домена, нерегулярности, нарушения ограничения целостности, противоречия, дубликаты, недопустимые кортежи, отсутствующие

значения, отсутствующие кортежи. Представьте результаты в табличном и графическом виде.

6. Вычислите показатели качества данных: полноту, достоверность, согласованность, соответствие схеме, однородность, плотность, уникальность.
7. По результатам исследования сделайте выводы о качестве данных.

### Варианты индивидуальных заданий

*Таблица 4.3.* Варианты наборов данных для обработки

| № | Данные из datasets | Внешние данные |
|---|---|---|
| 1. | airmiles | Latest Global Temperatures (https://www.kaggle.com/datasets/csafrit2/latest-global-temperatures) |
| 2. | AirPassengers | Finance companies in India (https://www.kaggle.com/datasets/anuragbantu/finance-companies-in-india) |
| 3. | airquality | Black Friday Sales EDA (https://www.kaggle.com/datasets/pranavuikey/black-friday-sales-eda) |
| 4. | anscombe | Football Transfers from 1992/93 to 2021/22 seasons(https://www.kaggle.com/datasets/cbhavik/football-transfers-from-199293-to-202122-seasons) |
| 5. | attenu | World, Region, Country GDP/GDP per capita (https://www.kaggle.com/datasets/tmishinev/world-country-gdp-19602021) |
| 6. | attitude | Air Pollution Level (https://www.kaggle.com/datasets/totoro29/air-pollution-level) |
| 7. | austres | Stack Overflow Developer Survey 2011-2022 (https://www.kaggle.com/datasets/yasirabdaali/stack-overflow-developer-survey-20112022) |
| 8. | beaver1 | Financing Healthcare (https://www.kaggle.com/datasets/programmerrdai/financing-healthcare) |
| 9. | beaver2 | Law School Admissions Bar Passage (https://www.kaggle.com/datasets/danofer/law-school-admissions-bar-passage) |
| 10. | beavers | Vending Machine Sales (https://www.kaggle.com/datasets/awesomeasingh/vending-machine-sales) |
| 11. | BJsales | Global Companies dataset (https://www.kaggle.com/datasets/narayan63/global-companies- |

| | | |
|---|---|---|
| | | dataset) |
| 12. | BJsales.lead | Smoke Detection Dataset (https://www.kaggle.com/datasets/deepcontractor/smoke-detection-dataset) |
| 13 | BOD | Netflix Data: Cleaning, Analysis and Visualization (https://www.kaggle.com/datasets/ariyoomotade/netflix-data-cleaning-analysis-and-visualization) |
| 14. | cars | World Population by Countries Dataset (1960-2021) (https://www.kaggle.com/datasets/kaggleashwin/population-dataset) |
| 15. | ChickWeight | Online Retails Sale Dataset (https://www.kaggle.com/datasets/rohitmahulkar/online-retails-sale-dataset) |
| 16. | chickwts | Spotify unpopular songs (https://www.kaggle.com/datasets/estienneggx/spotify-unpopular-songs) |
| 17. | CO2 | Chocolate Bar Ratings (https://www.kaggle.com/datasets/evangower/chocolate-bar-ratings) |
| 18. | co2 | Airbnb Open Data (https://www.kaggle.com/datasets/arianazmoudeh/airbnbopendata ) |
| 19. | crimtab | IMDB Movies (https://www.kaggle.com/datasets/totoro29/imdb-movies) |
| 20. | DNase | Youtube Statistics (https://www.kaggle.com/datasets/advaypatil/youtube-statistics ) |

## Список литературы


1. *Арустамов А.* Критерии качества данных. – Режим доступа: https://loginom.ru/blog/data-quality-criteria
2. *Müller H., Freytag J.-Chr.* Problems, Methods, and Challenges in Comprehensive Data Cleansing (Проблемы, методы и вызовы комплексной очистки данных, перевод статьи). – Режим доступа: https://habr.com/ru/articles/548356/
3. *Кабаков Р.И.* R в действии. Анализ и визуализация данных в программе R / пер. с.англ. Полины А. Волковой. – М.: ДМК Пресс, 2014. – 588 с.
4. *Уикем Х., Гроулмунд Г.* Язык R в задачах науки о данных импорт, подготовка, обработка, визуализация и моделирование данных. – СПб.: Диалектика, 2018. – 592 с.
5. ГОСТ Р ИСО 8000-2-2019. Качество данных. Часть 2. Словарь.
6. ГОСТ Р 57773-2017 (ИСО 19157:2013) Пространственные данные. Качество данных